

基于 a-PPO 算法的列检机械臂在线运动规划方法

赵 舵, 谢冠豪, 王叶文, 赵文杰, 黄 晨, 袁昭辉

(西南交通大学电气工程学院, 四川 成都 611756)

摘 要: 为满足列车底部场景中巡检机械臂主动配合工作人员的人机协作需求, 并提高 PPO (proximal policy optimization) 算法的收敛速度, 提出一种自适应 PPO (adaptive-PPO, a-PPO) 算法, 并将其应用于列检机械臂的在线运动规划. 首先, 设计系统模型, 根据当前环境状态即刻输出策略动作; 然后, 引入几何强化学习构建奖励函数, 通过智能体的探索不断优化奖励值分布; 接着, 基于策略更新前后的相似度自适应地确定裁剪值, 形成 a-PPO 算法; 最后, 通过在二维地图上对比分析 a-PPO 算法的改进效果, 并验证其在仿真和真实列车场景中的可行性和有效性. 结果表明: 在二维平面仿真中, a-PPO 算法在收敛速度上优于其他 PPO 算法, 且路径稳定性显著提高, 路径长度标准差平均比 PPO 算法低 16.786%, 比 Informed-RRT* 算法低 66.179%; 仿真与真实列车场景的应用实验中, 机械臂可实现运动过程中动态更改目标点和主动规避动态障碍物, 展现出对动态环境的适应能力.

关键词: 强化学习; 深度学习; 运动规划; 机械臂; 轨道列车

中图分类号: TP249 **文献标志码:** A

Online Motion Planning for Inspection Manipulator Based on Adaptive Proximal Policy Optimization Algorithm

ZHAO Duo, XIE Guanhao, WANG Yewen, ZHAO Wenjie, HUANG Chen, YUAN Zhaohui

(School of Electrical Engineering, Southwest Jiaotong University, Chengdu 611756, China)

Abstract: To meet the needs of human-robot collaboration, where an inspection manipulator actively cooperates with a person under the railroad car and to enhance the convergence speed of the proximal policy optimization (PPO) algorithm, an adaptive PPO (a-PPO) algorithm was proposed and innovatively applied in the online motion planning of the inspection manipulator. Firstly, the system model was designed to immediately output policy actions based on the current environmental state. Secondly, geometric reinforcement learning was introduced to construct the reward function, utilizing the agent's exploration to continuously optimize the distribution of rewards. Thirdly, the clipping value was adaptively determined based on the policy similarity between before and after the update, and the a-PPO algorithm was developed. Finally, the improvement effects of the a-PPO algorithm were compared on two-dimensional maps, and the feasibility and effectiveness of its application were experimentally verified in both simulation and real train scenarios. The results indicate that in the two-dimensional plane simulation, the a-PPO algorithm shows certain advantages in convergence speed compared to other PPO algorithms. Additionally, the stability of paths has been improved, with the average length standard deviation being 16.786% lower than that of the PPO algorithm and 66.179% lower than that of the Informed-RRT* algorithm. In the application experiments in both simulated and real train scenarios, the manipulator demonstrates the capability to dynamically adjust target points and actively avoid dynamic obstacles during

收稿日期: 2024-02-23 修回日期: 2024-04-30 网络首发日期: 2025-10-11

基金项目: 国家自然科学基金项目(62173279, U1934221)

第一作者: 赵舵(1975—), 男, 副教授, 研究方向为机器人控制, E-mail: zhaoduo@swjtu.edu.cn

引文格式: 赵舵, 谢冠豪, 王叶文, 等. 基于 a-PPO 算法的列检机械臂在线运动规划方法[J]. 西南交通大学学报, 2026, 61(1): 167-177.

ZHAO Duo, XIE Guanhao, WANG Yewen, et al. Online motion planning for inspection manipulator based on adaptive proximal policy optimization algorithm[J]. Journal of Southwest Jiaotong University, 2026, 61(1): 167-177.

motion, reflecting its adaptability to dynamic environments.

Key words: reinforcement learning; deep learning; motion planning; manipulator; railroad car

机械臂被广泛应用于现场巡检^[1-2]、智能制造^[3-4]和医疗陪护^[5-6]等领域,已成为提高工作效率、减轻人力负担的重要工具.当以列检机械臂为研究对象时,其运动规划成为关键研究内容.

运动规划的目标是实现机械臂从初始状态无碰撞地过渡到目标状态^[7].目前,机械臂运动规划大多采用离线方式,即先进行路径规划,再将路径转化为轨迹,最后按轨迹进行运动^[8-9].相关研究为列车底部巡检机械臂运动规划提供了不同思路.黄文东^[10]提出一种基于快速随机扩展树(RRT)与曲线拟合的算法用于列检机械臂运动规划,然而该方法难以兼顾运动的最优性、稳定性和实时性.Xie等^[11]提出一种基于深度强化学习的列检机械臂运动规划方法,以关节信息作为状态输入,以最大化累积奖励为目标,寻求收敛到最优的运动规划策略,可弥补传统运动规划方法的不足.

然而,当巡检机械臂与工作人员在列车巡检股道协同工作时,机械臂会面临动态障碍物.若当前目标点被工作人员遮挡,机械臂还需具备在线更改目标点的能力.因此,离线运动规划方法已无法满足现有需求.

过去,机器学习方法^[12-13]常面临巨大挑战,被认为不适用于高度不确定性的自动化过程,但近年来,深度学习的发展推动了强化学习的突破^[14-15].无模型深度强化学习已成为处理如在线运动规划这类复杂、未知、实时决策或高维问题的常用方法,在机器人运动规划中得到广泛应用^[16-19].Schulman等^[20]提出的PPO(proximal policy optimization)算法是一种基于策略函数的强化学习算法,该算法引入裁剪函数替代TRPO(trust region policy optimization)^[21]的相对熵函数,在重要性采样过程中限制更新前后策略分布的差异,降低了计算复杂度,适用于处理高维、连续和复杂的任务.然而,这种固定的裁剪策略会导致训练效率和收敛速度下降.为此,相关研究为PPO算法提供了多种改进思路.Xie等^[11]提出的随机PPO(RPPO)算法设计了一种随机裁剪策略,在训练初期随机放大裁剪阈值,以提升收敛速度和训练效率.Wen等^[22]提出动态PPO(dynamic-PPO)算法,设计一种动态裁剪策略,可自适应调整每个策

略梯度的裁剪阈值,以获得更好的约束效果,旨在提高学习性能.

基于此,本文综合相关研究,提出一种基于更新前后策略相似度的自适应裁剪方法,用以改进PPO算法中裁剪值固定的不足,将改进后的算法称为a-PPO(addaptive-PPO).此改进方式旨在保留策略梯度中有益方向的激励强度,提高训练的收敛速度.进一步,本文将a-PPO算法应用于列检机械臂在线运动规划,训练强化学习智能体,依据当前状态实时生成机械臂控制策略,以满足巡检机械臂主动配合工作人员的人机协作需求.此外,本文结合几何强化学习(GRL)^[23]对奖励函数进行建模,以优化奖励值分布,使奖励梯度朝着最优路径下降,降低智能体陷入局部最优点的风险.

1 系统模型

鉴于巡检机械臂需要满足人机协作的需求,其在线运动规划系统应根据当前环境状态即时输出策略动作,从而实现躲避动态障碍物以及动态更新目标点的目标.基于此,设计的系统模型如图1所示.图中:FC为全连接层,Tanh为双曲正切函数.

为获取列车底部精确的环境信息,系统借助激光雷达进行点云建图.鉴于机械臂的结构及障碍物的点云数据较为复杂,碰撞检测计算量较大,本文将点云地图映射为栅格地图.另外,依据机械臂运动学原理,靠近底座的3个关节对机械臂整体位姿影响最为显著,靠近末端的3个关节主要影响末端的姿态.所以,在线运动规划系统主要关注前3个关节.而后3个关节因运动范围较小,对工作人员影响不大,可直接采用传统规划算法求解.该系统采用异步优势行动者批评家框架^[24],基于a-PPO算法,可实现多个场景同时训练,有效提高训练效率.本系统还结合GRL的思想对奖励函数进行建模,使奖励梯度朝着最优路径方向下降,减少了因奖励值估计偏差过大致使智能体陷入局部最优点的情况.在环境板块中,每个场景持续向奖励估计值 G 矩阵集中输出训练数据并更新对应矩阵. G 矩阵能够依据智能体在环境中探索的数据,不断更新自身的奖励元素,以降低奖励值的估计偏差.最后,把对应的奖励、状态和动作序列存入数据存储器,以供智能体更新网络.




图1 列车底部巡检机械臂在线运动规划系统模型

Fig. 1 Online motion planning system model of inspection manipulator under railroad car

2 奖励函数建模

在机械臂运动规划中,无论是离线规划还是在线规划,通常采用启发式方法来评估从起点到目标点的总成本。第 t 步的总成本为

$$f(t) = g(t) + h(t), \quad (1)$$

式中: $g(t)$ 为从起点到当前点的实际成本, $h(t)$ 为从当前点到目标点的估计成本。

由于智能体仅依据当前状态做出动作决策,所以 $g(t) = 0$ 。考虑到难以直接获得当前点到目标点的最优路径来估计 $h(t)$,传统方法转而基于当前点 i 到目标点 m 的欧氏距离 $d_{i,m}$ 及其惩罚项 P (式(2))来确定奖励值。

$$P = \begin{cases} K_0 e^{-d_{i,n}}, & d_1 < d_{i,n} \leq d_2, \\ 2K_0, & 0 < d_{i,n} \leq d_1, \end{cases} \quad (2)$$

式中: $d_{i,n} = \sqrt{(x_i - x_n)^2 + (y_i - y_n)^2 + (z_i - z_n)^2}$, (x_i, y_i, z_i) 和 (x_n, y_n, z_n) 分别为当前点 i 和最近障碍物 n 的坐标; d_1 和 d_2 分别为危险区和警戒区的阈值; K_0 为惩罚强度系数。

那么,当前点的环境奖励值可表示为

$$R = -(k_1 d_{i,m} + k_2 P), \quad (3)$$

式中: k_1 和 k_2 分别为调整距离奖励和惩罚强度的系数。

列车巡检股道的实际环境及其点云地图如图2所示。可见,列车底部硬件繁多且布局复杂,还存在着诸如图3所示的凹形车钩连接件。这类形状

发策略梯度的错误,使智能体陷入局部最优点。为更直观地展现列车底部凹形车钩连接件对奖励值分布的影响,本文将抽象至二维平面,规划现象及其奖励值分布如图4所示。图4(a)中,斜线阴影区域为危险区域,点状阴影为警告区域,白色区域为可行区域,小圆代表起点,大圆代表终点区域。




图2 真实场景及其点云地图

Fig. 2 Real scenario and its point cloud map




图3 列车底部凹形车钩连接件

Fig. 3 Concave coupling component under railroad car

由此可见,在此环境下奖励分布异常,存在局部极值点。因此,面对特殊形状的障碍物,构建合理的奖励函数是一项挑战。为此,本文提出一种列车底部

场景下奖励函数的建模方法,该方法在某些方面与 GRL 算法或其变体相似,后者已被证明是一种有效的节点值估计方法^[25].




图 4 智能体陷入局部最优点的现象及其奖励分布
Fig. 4 Phenomenon of agent falling into a local optimal solution and its reward distribution

首先,依据当前点到障碍物的最短距离,建立高斯分布函数以估计碰撞概率 p ,如式(4)所示.

$$p = \begin{cases} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{d_{i,n}^2}{2\sigma^2}}, & d_{i,n} \geq d_1, \\ \frac{1}{\sqrt{2\pi}\sigma}, & 0 \leq d_{i,n} < d_1, \end{cases} \quad (4)$$

式中: σ 为高斯分布的标准差.

估计点 i_1 到 i_2 间运动的碰撞惩罚为

$$P_{i_1,i_2} = \int_C dp ds, \quad (5)$$

式中: d 为路径 C 上点到终端的欧氏距离.

确定两点间运动的代价为

$$H_{i_1,i_2} = k_1 d_{i_1,i_2} + k_2 P_{i_1,i_2}. \quad (6)$$

与式(3)不同的是, i_1 到 i_2 仅是智能体一个步长的距离.

最后,创建奖励估计值 G 矩阵.在智能体探索

的每步中,比较前一个点的奖励估计值 G_{i_1} 和后一个点的奖励估计值 G_{i_2} 加上两点之间运动的代价,取两者中的最小值更新 G 矩阵,可表示为

$$G_{i_1} = \min \{G_{i_1}, H_{i_1,i_2} + G_{i_2}\}, \quad (7)$$

$$G_{i_2} = \min \{G_{i_2}, H_{i_2,i_1} + G_{i_1}\}. \quad (8)$$

因此,智能体在探索的过程中持续优化 G 矩阵,奖励的估计值将不断趋近真实值,最终使奖励梯度朝着最优路径下降,如图5所示.




图 5 改进后的奖励函数生成的奖励分布
Fig. 5 Reward distributed map generated by improved reward function

将式(3)作为奖励 1, G 矩阵的奖励值为奖励 2.奖励 1 的优势在于仅考虑当前点的情况,虽为有偏估计,但节点间奖励方差较小,计算量也更小,适用于局部最优解较少的环境.奖励 2 需要考虑当前点直至目标点的预估路径情况,在智能体搜索过程中往往能使奖励趋近真实值,偏差量较小,但计算量较大,适用于局部最优解较多的环境.因此,本文在训练初期将奖励 1 作为环境奖励反馈,当训练过程中智能体陷入局部最优解时,使用奖励 2.

3 改进的 PPO 算法

作为近年来优秀的强化学习算法之一,PPO 在众多领域中表现出色.传统的策略梯度(PG)算法对新旧策略的差异性非常敏感.PPO 作为一种新型 PG 算法,通过裁剪新旧策略概率比来限制差异性,提高了训练的效率和稳定性.

目前,多数 PG 算法采用广义优势估计器(GAE)方法来估计优势函数,以调整训练数据的方差和偏差.GAE 对优势函数进行多步估计,并与衰减系数相结合.优势函数和第 t 步的时序差分(TD)误差 δ_t 的估计分别为

$$\begin{cases} A(s_t, a_t) = \hat{\delta}_t + (\gamma\lambda)\hat{\delta}_{t+1} + \\ (\gamma\lambda)^2\hat{\delta}_{t+2} + \dots + (\gamma\lambda)^{T-t-1}\hat{\delta}_{T-1}, \\ \hat{\delta}_t = r_t + \gamma V(s_{t+1}) - V(s_t), \end{cases} \quad (9)$$

式中: s_t 、 r_t 和 a_t 分别为第 t 步的状态、奖励和动作; T 为终止时间步; $V(\bullet)$ 为状态价值函数; γ 为奖励折扣因子; λ 为用于权衡单步和多步优势估计的超参数, 取值在 $0 \sim 1$ 之间。

λ 取值影响 GAE 对多步估计的侧重程度, λ 越接近 0, GAE 越趋向于强调单步估计; λ 越接近 1, GAE 越注重多步估计。

为解决网络更新后新策略 $\pi_\theta(\bullet)$ 无法重复利用上一周期策略 $\pi_{\theta_{\text{old}}}(\bullet)$ 的交互数据、导致数据利用率低的问题, PPO 算法引入重要性采样方法^[13], 得到当前策略梯度与新旧策略下累计奖励期望的关系如式(10)所示, θ 、 θ_{old} 为网络参数。

$$\begin{aligned} \nabla_\theta J(\theta) &= E_{\pi_\theta}(\nabla_\theta \log \pi_\theta(s, a) A(s, a)) = \\ &= \sum_{(s, a) \sim \pi_\theta} \pi_\theta(s, a) A(s, a) \nabla_\theta \log \pi_\theta(s, a) = \\ &= E_{\pi_{\theta_{\text{old}}}} \left(A(s, a) \frac{\nabla_\theta \pi_\theta(s, a)}{\pi_{\theta_{\text{old}}}(s, a)} \right), \end{aligned} \quad (10)$$

式中: $\pi_\theta(s, a)$ 为在状态 s 、动作 a 下的策略, $\pi_{\theta_{\text{old}}}(s, a)$ 为上一周期与环境交互的策略, $E_{\pi_\theta}(\bullet)$ 为策略分布 π_θ 下优势值的期望。

使用旧策略采样的数据计算新策略下累积优势值的期望, 可被视为一种无偏估计。因此, 策略网络的目标函数可表示为

$$L(\theta) = E_{\pi_{\theta_{\text{old}}}}(h(\theta)A(s, a)), \quad (11)$$

式中: $h(\theta) = \pi_\theta(s, a)/\pi_{\theta_{\text{old}}}(s, a)$ 。

然而, 新、旧策略概率分布对应的优势值期望分布方差 $D_{\pi_\theta}(A(s, a))$ 、 $D_{\pi_{\theta_{\text{old}}}}(A(s, a)h(\theta))$ 并不相同, 其差值为

$$\begin{aligned} \Delta D &= D_{\pi_\theta}(A(s, a)) - D_{\pi_{\theta_{\text{old}}}}(A(s, a)h(\theta)) = \\ &= E_{\pi_\theta}(A^2(s, a)) - E_{\pi_\theta}(A^2(s, a)h^2(\theta)), \end{aligned} \quad (12)$$

式中: $D_{\pi_{\theta_{\text{old}}}}(A(s, a)h(\theta)) = E_{\pi_{\theta_{\text{old}}}}(A^2(s, a)h^2(\theta)) - E_{\pi_{\theta_{\text{old}}}}^2(A(s, a)h(\theta)) = E_{\pi_\theta}(A^2(s, a)h^2(\theta)) - E_{\pi_\theta}^2(A(s, a))$, $D_{\pi_\theta}(A(s, a)) = E_{\pi_\theta}(A^2(s, a)) - E_{\pi_\theta}^2(A(s, a))$ 。

由此可见, 若两概率分布差异性过大, 重要性采样的性能便会变差。为减弱这种不良影响, PPO 算法引入裁剪函数, 其策略损失函数如式(13)所示。

$$L_{\text{clip}}(\theta) = E(\min\{f_{\text{clip}}(h(\theta), 1 - \varepsilon, 1 + \varepsilon)A(s, a), h(\theta)A(s, a)\}), \quad (13)$$

式中: ε 为调节裁剪区间的参数, $f_{\text{clip}}(\bullet)$ 为裁剪函数, $f_{\text{clip}}(h(\theta), 1 - \varepsilon, 1 + \varepsilon)A(s, a)$ 消除了 $h(\theta)$ 在 $[1 - \varepsilon, 1 + \varepsilon]$ 区间之外的激励。

然而, PPO 的性能对裁剪参数 ε 高度敏感, 选择合适的 ε 颇具挑战性。因此, 本文提出一种基于更新前后策略相似度的自适应方法来确定 ε 值, 从小批量训练数据中推导 ε 值, 而非保持固定, 如式(14)所示。

$$\varepsilon = \mu + k_3 \frac{\min \left\{ k_4, \sum_{(s, a) \sim \pi_{\theta_{\text{old}}}} I(|h(\theta) - 1| > \mu) \right\}}{k_4}, \quad (14)$$

式中: k_3 和 k_4 分别为自适应裁剪项的权重系数和容量; M 为小批量数量; μ 为基准截断参数; $I(\bullet)$ 为指示函数, 当条件为真时返回 1, 否则返回 0。

a-PPO 采用在策略和价值函数之间共享参数的神经网络架构, 需结合价值函数误差项构建损失函数。为保证充分探索, 损失函数还添加了熵函数项。因此, 最终的目标函数为

$$L(\theta) = E(L_{\text{clip}}(\theta) - c_1 L_{\text{VF}}(\theta) + c_2 S_{\pi_\theta}(s)), \quad (15)$$

式中: $S_{\pi_\theta}(s)$ 为策略分布 π_θ 的熵函数, $L_{\text{VF}}(\theta)$ 为状态价值估计值与实际值的平方差函数, c_1 和 c_2 为权重系数。

4 实验分析

本文通过仿真与实物实验, 分析基于 a-PPO 的在线运动规划方法的性能。首先, 为证明 a-PPO 的收敛速度更快, 且输出路径具备最优性和稳定性, 将其与其他算法的收敛曲线和生成路径进行对比; 然后, 将 a-PPO 算法应用于巡检机械臂在线运动规划中, 以验证本文方法的有效性和可行性。

自动导向小车 (AGV) 每个停车点存在多个拍摄点, 巡检机械臂在线运动规划的训练流程如图 6 所示。

参数设置如表 1 所示, 本次实验将 G 矩阵设置为 36 阶。采用基于 Linux 内核的 Ubuntu 20.04 系统, 软件主要基于 Python 3.9 和 C++ 17, 借助 ROS 平台实现对机械臂的控制, 并使用 PyTorch、MoveIt、点云库和碰撞检测库等库。实验硬件采用 AMD Ryzen 7 5800H 中央处理器、NVIDIA GeForce RTX 3060 图形处理单元, 机械臂选用 6 轴协作机械臂。




图 6 机械臂训练流程

Fig. 6 Process of manipulator training

表 1 实验参数设置

Tab. 1 Experimental parameter settings

参数	值
学习率	3×10^{-4}
折扣因子	0.99
迭代的最大步数/步	1.5×10^3
小批量数量/批	4×10^3
每次小批量更新网络的次数/次	80
训练的总轮数/轮	1.1×10^3
优势函数因子	0.99
策略网络输出的动作分布标准差	0.5
基准截断参数值	0.2
碰撞概率高斯分布标准差	0.5
k_1	2
k_2	40
k_3	0.1
k_4	900
c_1	0.5
c_2	0.01

4.1 仿真实验

4.1.1 二维空间路径规划仿真实验

在二维空间中,对比 RRT* (快速扩展随机树星)、RRT-connect (双向快速扩展随机树)、Informed-RRT* (启发式快速扩展随机树星)、PPO、RPPO、Dynamic-PPO 和 a-PPO 算法的性能差异进行实验,选取 3 个具有代表性的静态场景和 1 个动态场景.上述算法经 100 次实验后得到的最短路径如图 7 所示,实验结果见表 2,收敛性能对比如图 8 所示.

对比图 7 和表 2 的实验结果可以看出: Informed-RRT* 在平均值和最小值方面均表现出最佳性能, PPO 及其衍生算法则在最大值和标准差方面更具优势. 其中, a-PPO 算法的标准差平均比原 PPO 低 16.786%, 比 Informed-RRT* 低 66.179%, 且在平均值和最小值方面也有不错的表现. 这是因为 Informed-RRT* 基于随机探索策略, 优化已有的随机树以寻求更短的路径, 仅进行碰撞检测而不考虑潜在碰撞风险, 因而表现出更好的平均值和最小值, 但其稳定性和安全性是难以保证的. 而 PPO 及其衍生算法生成的路径柔顺性、稳定性和安全性更好, 这得益于他们采用基于学习的方法, 考虑长期收益和潜在的碰撞风险, 更适合处理本文这一类对算法输出路径安全性和稳定性要求较高的任务.

此外, 通过对比 PPO 及其衍生算法的收敛曲线可以发现, a-PPO 算法表现出更好的收敛性能. 这是由于 a-PPO 算法的裁剪值在每轮小批量更新时, 根据当前策略网络与上一周期网络的相似性自适应确定, 从而灵活调整每次网络更新的最大步长, 因此其收敛速度最快. 相比之下, 尽管 RPPO 在训练末期通过固定裁剪值降低了网络波动, 在路径标准差方面略有优势, 但因其裁剪阈值具有随机性, 随机范围不宜设置过大, 以避免影响收敛稳定性, 故而收敛速度不及 a-PPO. Dynamic-PPO 为每个梯度自适应设置裁剪值, 裁剪的稳定性不如 a-PPO, 易放大错误方向的激励强度, 因此收敛速度也比 a-PPO 稍慢. 综上, 由于动态场景下的任务需要同时进行训练和动作输出, 更注重收敛速度, 以便及时调整策略. 而 a-PPO 收敛速度更快, 更适合处理此类任务.




图 7 二维空间中进行 100 次实验后输出的最短路径对比

Fig. 7 Comparison of the shortest paths output after 100 experiments in two-dimensional space

表 2 二维空间下的实验数据
Tab. 2 Experimental data in two-dimensional space

场景	算法	最大值	最小值	平均值	标准差
静态场景 1	RRT-connect	218.67	132.09	147.59	13.01
	RRT*	199.65	125.47	148.52	16.50
	Informed-RRT*	151.99	122.87	126.81	4.32
	PPO	147.76	137.79	141.76	2.13
	RPPO	144.87	136.28	140.46	1.91
	Dynamic-PPO	150.16	137.09	143.16	2.29
静态场景 2	a-PPO	149.11	137.52	141.39	1.98
	RRT-connect	202.61	140.51	156.35	11.14
	RRT*	179.99	140.22	155.24	9.16
	Informed-RRT*	165.98	135.20	138.38	4.36
	PPO	142.79	131.77	141.01	2.33
	RPPO	145.92	137.04	140.57	1.67
静态场景 3	Dynamic-PPO	151.19	138.51	142.75	1.92
	a-PPO	141.61	133.16	137.01	1.86
	RRT-connect	255.77	124.29	169.83	29.49
	RRT*	241.27	124.05	163.99	33.66
	Informed-RRT*	190.79	116.97	126.13	18.89
	PPO	140.98	127.75	133.41	2.88
动态场景	RPPO	141.59	126.52	133.57	2.79
	Dynamic-PPO	146.42	128.72	135.69	4.21
	a-PPO	140.31	127.71	132.58	2.45
	PPO	151.32	138.36	141.95	2.28
	RPPO	145.74	138.97	141.40	1.52
	Dynamic-PPO	148.75	139.21	142.91	1.98
	a-PPO	148.48	138.09	141.77	1.71





图 8 PPO 及其衍生算法的收敛性能对比


Fig. 8 Comparison of convergence performance between PPO and its derived algorithms

4.1.2 机械臂路径规划仿真实验

通过仿真实验验证本文所述方法能否满足机械臂主动配合工作人员的人机协作需求. 第一, 验证算法在列车底部巡检股道下在线更新目标点的性能, 模拟原始目标被工作人员遮挡而暂时无法到达的情况, 如图9所示. 第二, 在原有巡检股道场景中添加动态人形障碍物以复现工作人员出现在机械臂附近的场景, 进而以验证算法的避险能力, 如图10所示.



(a) 机械臂运动过程



(b) 关节角度变化


图9 机械臂运动过程中更新终点的实验

Fig. 9 Experiment on updating end point during the movement of manipulator


图9(b)中, 横向虚线表示当前角度目标, 纵向虚线表示目标更新时刻. 实验结果显示, 机械臂前期朝着原始目标点运动, 时间为8.5 s时更新目标点后朝着新目标运动并抵达. 这是因为算法的状态包含运动的目标信息, 在某时刻改变状态的目标位置后, 得益于策略网络的泛化能力, 智能体仍然能提供面向新目标的动作值. 由此可见, 本文所述方法在机械臂运动过程中能够实现在线更新目标点.

图10(b)中, 纵向虚线表示动态障碍物与机械臂基座的距离小于阈值的时刻. 实验结果显示, 机械臂前期维持在原位置, 时间为7.7 s时动态障碍物靠近, 策略网络控制机械臂与工作人员始终保持

一定的安全距离, 当工作人员离开后, 机械臂重新运动至原位置. 这是因为算法的输入状态还包含动态障碍物的位置信息, 当股道内的障碍物与机械臂距离过近时智能体会获得相应惩罚, 通过多次试错训练智能体能够收敛至一个具备避障能力的策略网络. 同样地, 得益于该网络的泛化能力, 智能体还可处理不规则运动的动态障碍物, 无须对障碍物的运动进行预测. 由此, 该实验证实了基于a-PPO的机械臂在线运动规划方法具备实时躲避动态障碍物的能力.



(a) 机械臂避障过程



(b) 关节角度变化

图10 机械臂躲避动态障碍物实验

Fig. 10 Experiment on dynamic obstacle avoidance of manipulator

4.2 实物实验

为增强实物实验的真实性和结论的可靠性, 在真实列车底部场景下开展实验, 搭建的实验平台如图11所示.

分别验证机械臂实时更新目标点和实时躲避动态障碍物的运动规划性能, 实验结果如图12、图13所示.




图 11 机器人实验平台

Fig. 11 Experiment platform of robot




图 12 机械臂实时更新目标点实物实验

Fig. 12 Physical experiment of manipulator updating target point in real time



图 13 机械臂实时躲避动态障碍物实物实验

Fig. 13 Physical experiment of manipulator avoiding dynamic obstacles in real time

实验结果显示,机械臂在运动过程中改变目标点后,依然能够基于当前状态朝着最新目标点运动.这体现了机械臂运动规划的鲁棒性,即其能够在目

标发生变化时快速规划并到达新的目标.此外,在股道内的工作人员接近时,机械臂也能主动避让,这也体现了该方法能够有效确保机械臂适应存在动态障碍物的环境.因此在真实应用场景下,基于 a-PPO 的方法具备出色的在线运动规划能力,证明本文所述方法具有可行性和有效性.

5 结 论

1) 相较于 RRT 类算法,基于 PPO 及其衍生算法的在线运动规划方法所产生的路径兼顾了最优性和稳定性,更适用于对稳定性要求较高的应用场景.

2) 与 PPO 算法相比, a-PPO 算法收敛速度更快,输出运动路径稳定性更佳.此外,本文提出的奖励函数建立方法,可借助智能体的探索,不断优化更新奖励分布,使奖励梯度向最优路径下降,从而有效降低智能体陷入局部最优点的风险.

3) 基于 a-PPO 算法的机械臂在线运动规划方法可实现在运动过程中动态更改目标点和主动躲避动态障碍物,为开发机械臂主动配合工作人员的人机协作模式提供了重要支持.

参考文献:

- [1] JING G Q, QIN X Y, WANG H Y, et al. Developments, challenges, and perspectives of railway inspection robots[J]. *Automation in Construction*, 2022, 138: 104242.
- [2] OLLERO A, TOGNON M, SUAREZ A, et al. Past, present, and future of aerial robotic manipulators[J]. *IEEE Transactions on Robotics*, 2022, 38(1): 626-645.
- [3] 江海凡,丁国富,肖通,等.数字孪生演进模型及其在智能制造中的应用[J]. *西南交通大学学报*, 2022, 57(6): 1386-1394.
JIANG Haifan, DING Guofu, XIAO Tong, et al. Digital twin evolution model and its applications in intelligent manufacturing[J]. *Journal of Southwest Jiaotong University*, 2022, 57(6): 1386-1394.
- [4] GUALTIERI L, RAUCH E, VIDONI R. Emerging research fields in safety and ergonomics in industrial collaborative robotics: a systematic literature review[J]. *Robotics and Computer-Integrated Manufacturing*, 2021, 67: 101998.1-101998.30.
- [5] OMISORE O M, HAN S P, XIONG J, et al. A review on flexible robotic systems for minimally invasive surgery[J]. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2022, 52(1): 631-644.

- [6] 窦汝桐,于慎波,孙凤,等. 7 自由度仿人机械臂工作空间求解的降密蒙特卡洛法[J]. 西南交通大学学报, 2023, 58(6): 1328-1338.
- DOU Rutong, YU Shenbo, SUN Feng, et al. Density-reducing Monte Carlo method for 7 degrees of freedom humanoid robot arm workspace solution[J]. Journal of Southwest Jiaotong University, 2023, 58(6): 1328-1338.
- [7] BILAL H, YIN B Q, KUMAR A, et al. Jerk-bounded trajectory planning for rotary flexible joint manipulator: an experimental approach[J]. *Soft Computing*, 2023, 27(7): 4029-4039.
- [8] CHENG X, ZHOU J M, ZHOU Z, et al. An improved RRT-connect path planning algorithm of robotic arm for automatic sampling of exhaust emission detection in Industry 4.0[J]. Journal of Industrial Information Integration, 2023, 33: 100436.1-100436.13.
- [9] YU X L, DONG M S, YIN W M. Time-optimal trajectory planning of manipulator with simultaneously searching the optimal path[J]. *Computer Communications*, 2022, 181: 446-453.
- [10] 黄文东. 基于 ROS 的机械臂路径规划算法研究[D]. 成都: 西南交通大学, 2022.
- [11] XIE G H, ZHAO D, TANG Q C, et al. Path planning for robotic arm based on reinforcement learning under the train[C]//2023 IEEE International Conference on Robotics and Biomimetics (ROBIO). Koh Samui: IEEE, 2023: 1-8.
- [12] WANG M, FU W J, HE X N, et al. A survey on large-scale machine learning[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 34(6): 2574-2594.
- [13] WANG J J, MA Y L, ZHANG L B, et al. Deep learning for smart manufacturing: methods and applications[J]. *Journal of Manufacturing Systems*, 2018, 48: 144-156.
- [14] LE N, RATHOUR V S, YAMAZAKI K, et al. Deep reinforcement learning in computer vision: a comprehensive survey[J]. *Artificial Intelligence Review*, 2022, 55(4): 2733-2819.
- [15] JAMES S, MA Z C, ARROJO D R, et al. RL Bench: the robot learning benchmark & learning environment[J]. *IEEE Robotics and Automation Letters*, 2020, 5(2): 3019-3026.
- [16] TALAEI KHOEI T, OULD SLIMANE H, KAABOUC N. Deep learning: systematic review, models, challenges, and research directions[J]. *Neural Computing and Applications*, 2023, 35(31): 23103-23124.
- [17] SHAKYA A K, PILLAI G, CHAKRABARTY S. Reinforcement learning algorithms: a brief survey[J]. *Expert Systems with Applications*, 2023, 231: 120495.
- [18] LI Y K, HAO X L, SHE Y C, et al. Constrained motion planning of free-float dual-arm space manipulator via deep reinforcement learning[J]. Aerospace Science and Technology, 2021, 109: 106446.1-106446.13.
- [19] KIRAN B R, SOBH I, TALPAERT V, et al. Deep reinforcement learning for autonomous driving: a survey[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(6): 4909-4926.
- [20] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[DB/OL]. [2017-8-28]. <https://arxiv.org/abs/1707.06347>.
- [21] SCHULMAN J, LEVINE S, MORITZ P, et al. Trust region policy optimization[C]//Proceedings of the 31st International Conference on Machine Learning. Lille: PMLR, 2015: 1889-1897.
- [22] WEN S H, WEN Z T, ZHANG D, et al. A multi-robot path-planning algorithm for autonomous navigation using meta-reinforcement learning based on transfer learning[J]. *Applied Soft Computing*, 2021, 110: 107605.
- [23] ZHANG B C, MAO Z L, LIU W Q, et al. Geometric reinforcement learning for path planning of UAVs[J]. Journal of Intelligent & Robotic Systems, 2015, 77(2): 391-409.
- [24] MNIH V, BADIA A P, MIRZA M, et al. Asynchronous methods for deep reinforcement learning[C]//Proceedings of the 33rd International conference on machine learning. New York: PMLR, 2016: 1928-1937.
- [25] FUJINMOTO S, VAN HOOF H, MEGER, D. Addressing function approximation error in actor-critic methods[C]//Proceedings of the 35th International Conference on Machine Learning. Stockholm: PMLR, 2018: 1587-1596.

(中文编辑: 李永辉)