



组合机床与自动化加工技术

Modular Machine Tool & Automatic Manufacturing Technique

ISSN 1001-2265, CN 21-1132/TG

《组合机床与自动化加工技术》网络首发论文

题目：基于改进 PPO 算法的机器人机械臂抓取策略研究
作者：杨思祺，熊鸣，张巧杰，聂世纪，刘雨鑫
收稿日期：2025-07-01
网络首发日期：2026-01-28
引用格式：杨思祺，熊鸣，张巧杰，聂世纪，刘雨鑫. 基于改进 PPO 算法的机器人机械臂抓取策略研究[J/OL]. 组合机床与自动化加工技术.
<https://link.cnki.net/urlid/21.1132.TG.20260128.1430.078>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于改进 PPO 算法的机器人机械臂抓取策略研究

杨思祺 熊鸣 张巧杰 聂世纪 刘雨鑫

(北京信息科技大学自动化学院, 北京市, 100192)

摘要：传统近端策略优化算法因固定熵损失系数难以平衡探索与收敛，致训练效率受限。为此提出了一种基于贝叶斯优化的改进 PPO 算法，动态自适应调整熵损失系数以优化探索与利用权衡。实验在 MuJoCo 搭建机械臂抓取仿真环境，设计含关节角度、速度及目标偏差的 21 维状态空间，结合位置误差与控制代价的奖励函数，对比固定熵系数 PPO、自适应熵策略 PPO 与改进算法训练效果。结果显示，改进算法借贝叶斯优化全局搜索机制，使平均奖励获得提升，有效解决传统算法局部最优问题，为机械臂智能控制提供更优方案。

关键词：抓取策略；深度强化学习；PPO 算法；贝叶斯优化；熵损失系数

中图分类号：TP242

文献标识码：A

Research on Robot Manipulator Grasping Strategy Based on Improved PPO Algorithm

YANG Siqi, XIONG Ming, ZHANG Qiaojie, NIE Shiji, LIU Yuxin

(School of Automation, Beijing Information Science and Technology University, Beijing 100192, China)

Abstract: The traditional Proximal Policy Optimization algorithm struggles to balance exploration and convergence due to a fixed entropy loss coefficient, limiting training efficiency. To address this, an improved PPO algorithm based on Bayesian optimization is proposed, dynamically and adaptively adjusting the entropy loss coefficient to optimize the trade-off between exploration and exploitation. The experiment is conducted in a robotic arm grasping simulation environment built on MuJoCo, with a 21-dimensional state space incorporating joint angles, velocities, and target deviations. A reward function combining position error and control cost is used to compare the training performance of fixed entropy coefficient PPO, adaptive entropy strategy PPO, and the proposed algorithm. The results show that the improved algorithm, leveraging the global search mechanism of Bayesian optimization, increases the average reward, effectively solving the local optimum problem of the traditional algorithm and providing a better solution for robotic arm intelligent control.

Keywords: Grasping Strategy; Deep Reinforcement Learning; PPO Algorithm; Bayesian Optimization; Entropy Loss Coefficient

收稿日期：2025-7-1

基金项目：国家自然科学基金 (62071469)

作者简介：杨思祺 (2000-)，男，硕士研究生，研究方向为双臂机器人协同控制策略，(E-mail)

1436223448@qq.com；通信作者：熊鸣 (1978-)，男，高级实验师，硕士生导师，博士，研究方向为机器人控制，(E-mail) xmee@bistu.edu.cn。

0 引言

随着社会不断发展, 机器人应用领域逐步扩展到服务和医疗行业, 如人工辅助、康复治疗、老年人护理及危险环境救援等^[1]。机械臂作为人形机器人实现高水平交互与环境适应能力的关键组件, 精确操控与灵活抓取能力已然成为研究的焦点。

深度强化学习是一种结合了深度学习感知能力和强化学习决策能力的方法, 使得机器人可以在复杂环境下自主完成抓取任务, 从而提升智能性与灵活性^{[2][3]}。深度强化学习算法作为深度学习领域的一个重要分支, 能够为计算机从感知到决策提供解决方案, 从而实现智能控制^[4]。这一算法已经在多个领域有了实际应用, 并且取得了显著的应用成果, 例如无人机控制^[5]、车辆自动驾驶控制^[6]以及机械臂控制^[7]等方面。田成军等人^[8]提出结合先验知识的改进 TD3 算法, 通过多经验池设计和分层奖励函数, 成功解决训练初期数据稀疏问题。周旗龙等人^[9]通过融合 TD3 和 HER 技术, 显著提升了机械臂的控制性能。王永华等人^[10]通过构建六维改进 PPO 框架, 系统分析了多改进项对 PPO 性能的影响, 使机械臂奖励曲线获得大幅提升, 但其熵损失仍采用静态参数。李锦键等人^[11]提出自适应熵损失系数策略, 通

过比较当前与历史训练回合的目标函数值, 动态调整熵损失权重, 解决 PPO 算法固定熵参数导致的局部最优问题, 但依赖目标函数更新的方法仅通过历史均值与当前值偏差调整参数, 容易导致探索策略调整滞后, 造成与任务需求脱节等问题。

针对上述问题, 文本为以 PPO 算法为原始模型, 通过引入贝叶斯优化算法 (Bayesian Optimization, BO) 去调整超参数^[12], 对 PPO 算法中的熵损失系数进行动态自适应调整。本研究的创新性在于, 将贝叶斯优化算法与 PPO 算法的熵损失系数相结合, 提出了一种新的训练策略, 能够自适应调整超参数, 使平均奖励提升得到提升, 从而显著提高机械臂在动态环境中的抓取能力, 有效解决传统算法局部最优问题, 为机械臂智能控制提供更优方案。

1 实验过程设计

本实验的主要目标是以 PPO 算法为基础, 以及引入贝叶斯优化, 自动调节 PPO 算法中的熵损失系数得到改进后的 PPO 算法。通过合理的状态空间、动作空间以及奖励函数的设计, 使机器人机械臂抓取环境更加易于智能体学习, 最后通过平均奖励曲线进而评估改进后的 PPO 算法相较于原 PPO 算法的优势以及提升。实验流程如图 1 所示。




图 1 实验流程

2 深度强化学习算法

2.1 PPO 算法

近端策略优化是一种基于策略梯度的强化学习算法，是通过迭代优化智能体的策略来实现在环境中选择最佳动作以最大化累积奖励，策略是一个映射，定义了在一定状态下智能体如何选择动作^[13]。在 PPO 算法中，智能体的策略由一个参数化的概率分布表示，记为 $\pi_{\theta}(a|s)$ ，其中 θ 为策略的参数， s 表示当前的状态， a 表示采取的动作^[14]。PPO 算法框架如图 2 所示。




图 2 PPO 算法框架结构图

PPO 算法的核心思想是通过限制新旧策略之间的差异，避免破坏性的大幅度更新，以确保算法的稳定性。引入了裁剪损失函数和重要性采样技术，

通过定义概率比率 $r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$ ，来衡量新旧策

略在状态 s_t 下采取动作 a_t 的概率差异，其中 $\pi_{\theta_{old}}$ 为更新前的策略函数， π_{θ} 为更新后的策略函数。裁剪损失函数如下：

$$L_t^{CLIP}(\theta) = \hat{E}_t \left[\min \left(r_t(\theta) \cdot \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (1)$$

$r_t(\theta)$ 为新旧策略比值， $\hat{E}_t$ 为 t 时刻函数的期望， $\hat{A}_t$ 为优势函数， clip 为一个约束函数，用于对比率进行截断以确保其在 $[1 - \epsilon, 1 + \epsilon]$ 范围内， ϵ 为裁剪系数。

在本实验中，将机器人机械臂系统的状态空间

定义为一个 21 维的向量。这个状态空间包含了 7 个关节的角度信息、7 个关节的角速度，以及每个关节的角度与目标角度之间的偏差。具体而言，状态空间可以表示为：

$$S = [\theta_i, \dot{\theta}_i, (\theta_i - \theta_i^{goal})] \quad (2)$$

其中， θ_i 表示第 i 个关节的当前角度， $\dot{\theta}_i$ 表示第 i 个关节的角速度， θ_i^{goal} 则表示第 i 个关节的目标角度。

为模拟真实机器人中的不确定性，本文引入高

斯噪声干扰，对于关节角度 $\hat{\theta}_i$ 以及关节角速度 $\hat{\dot{\theta}}_i$ ，

采用如下带有高斯噪声的模型：

$$\begin{cases} \hat{\theta}_i = \theta_i + \varepsilon_{\theta,i}, & \varepsilon_{\theta,i} \sim N(0, \sigma^2) \\ \hat{\dot{\theta}}_i = \dot{\theta}_i + \varepsilon_{\dot{\theta},i}, & \varepsilon_{\dot{\theta},i} \sim N(0, \sigma^2) \end{cases} \quad (3)$$

$\sigma = 0.1$ ，为高斯噪声的标准差， $\varepsilon_{\theta,i}$ 和 $\varepsilon_{\dot{\theta},i}$ 分别为独立同分布的角度与速度噪声项。该设计使训练环境更贴近物理世界中机械臂的实际感知场景，可有效验证算法在噪声干扰下的抗扰动能力与决策鲁棒性。

其次，动作空间被定义为一个 7 维的向量，控制机械臂右臂的 7 个关节角度增量。每个关节的角度增量根据范围进行限制，以确保机器人机械臂动作的合理性。通过不断调整关节角度，智能体能够在训练过程中学习如何使末端执行器达到目标位置，完成任务，动作空间可以表示为：

$$A = (a_i) \quad (4)$$

每个元素 a_i 是第 i 个关节的角度增量，单位为弧度。对于机械臂的每个关节 i ，其当前的角度由 $\theta_i^{current}$ 表示，更新后的角度为：

$$\theta_i^{new} = \theta_i^{current} + a_i \quad (5)$$

这里， θ_i^{new} 表示更新后的关节角度， $\theta_i^{current}$ 是当前的关节角度，而 a_i 是从动作空间中获取的关节角度增量。

最后，本文的奖励函数通过综合考虑位置误差

和控制代价，以减少末端执行器与目标之间的距离的同时，避免不必要的过度动作^[15]。通过这种设计，奖励函数可以促使智能体朝着目标位置移动，还能有效地约束机械臂的运动，以达到稳定、高效的操作效果。奖励函数的表达式如下：

$$R = \alpha \cdot reward_dist + \beta \cdot reward_ctrl \quad (6)$$

$reward_dist$ 是基于末端执行器的当前位置和目标位置的欧几里得距离的奖励，具体公式如下：

$$reward_dist = -\|P_{current} - P_{goal}\| \quad (7)$$

$\|P_{current} - P_{goal}\|$ 计算了末端执行器当前位置与目标位置之间的欧几里得距离，距离越小所获得的奖励越高。

$reward_ctrl$ 是基于控制代价的奖励，用来约束关节角度的变化。关节角度的平方和能够有效地惩罚较大的关节角度变化，具体为：

$$reward_ctrl = -0.01 \cdot \sum_{i=1}^7 a_i^2 \quad (8)$$

a_i 是第 i 个关节的动作增量，控制代价通过约束关节角度的增量来避免剧烈的动作。

2.2 熵损失系数

熵损失系数在策略梯度方法中起到了平衡探索与开发的作用。对于 PPO 算法，熵损失系数会直接

影响到目标函数中的熵项，其中，熵项的引入主要是为了防止策略变得过于确定性，从而导致陷入局部最优解，用来增加探索的多样性。在 PPO 算法中，目标函数可以表示为：

$$L_t(\theta) = \hat{E}_t[L_t^{CLIP}(\theta) - c_1 L_t^V + \omega S(\pi_\theta)] \quad (9)$$

$$S(\pi_\theta) = -\sum \pi_\theta(a|s) \log \pi_\theta(a|s) \quad (10)$$

c_1 为平方误差系数； ω 为熵损失系数； L_t^V 为价值函数的损失； $S(\pi_\theta)$ 为策略函数的熵。

熵损失系数作为一个关键参数，影响着智能体对于动作的更新。当熵损失系数过高时，智能体动作的不确定性会增高，从而进行更多探索，帮助智能体更快跳出局部最优；当熵损失系数过低时，智能体动作的不确定性会减弱，易陷入局部最优，导致最终不能收敛至最优结果^[11]。

2.3 改进的 PPO 模型建立

在使用深度强化学习进行机器人机械臂抓取训练过程中，PPO 算法因其良好的稳定性被广泛应用于机械臂抓取任务等连续控制任务中，但在传统方法中，熵损失系数被设定为固定值或是事先定义的策略等，这类方法缺乏对任务奖励的适应能力，容易使智能体在探索过程中出现探索不足或探索过度等问题。因此，为了解决熵损失系数难以确定的问

题，本文将在 PPO 算法的基础上，引入贝叶斯优化方法，对 PPO 算法中的熵损失系数进行自适应调整^{[16][17]}，提出一种熵损失自适应的改进 PPO 优化算法，从而使得智能体在寻优过程中平衡探索与利用。

改进的 PPO 算法的具体实现流程如下：

1) 初始化阶段

在贝叶斯优化的初始阶段，需要为熵损失系数设定初始值和优化的范围。选择一个初始的 ω_0 ，作为优化的起点，并设定搜索范围 $[\omega_{\min}, \omega_{\max}]$ ，保证熵损失系数不会超出合理范围。

2) 评估回报

每当熵损失系数 ω 发生变化时，需要评估当前策略的汇报表现通过计算最近的 N 个 *episode* 的平均奖励来作为汇报表现，即如下式所示：

$$\hat{R}(\omega) = \frac{1}{N} \sum_{i=1}^N r_i \quad (11)$$

其中， r_i 为第 i 个 *episode* 的回报。

3) 训练代理模型

本文采用高斯过程 (Gaussian Processes, GP) 作为概率代理模型。高斯过程是多元高斯概率分布的泛化，能够近似各种类型的函数。高斯过程是通过均值函数 μ 以及协方差函数 σ^2 来描述目标函数的预测分布^[18]，其核心公式如下：

$$\mu(x) = k(x, X)^T K^{-1} y \quad (12)$$

$$\sigma^2(x) = k(x, x) - k(x, X)^T K^{-1} k(x, X) \quad (13)$$

其中, $k(x, X)$ 为输入点和训练点之间的协方向量; $k(x, x)$ 为输入点和自身之间的协方差; K 为训练数据的协方差矩阵; y 为回报的向量, 即目标函数的值。

通过历史数据 $(\omega, \hat{R}(\omega))$ 训练高斯过程, 得到回报函数的均值 $\mu(\omega)$ 和方差 $\sigma^2(\omega)$ 。

4) 选择新的熵损失系数 ω

本文采用期望提升策略作为 (Expected Improvement, EI) 作为采集函数。EI 是通过衡量当前最优点的期望提升量来选择下一个评估点, 以带来比现有最优值更高回报的期望^[19], 其公式如下

所示:

$$\begin{cases} EI(x) = (f(x^*) - \mu(x)) \phi(Z) + \sigma(x) \Phi(Z) \\ Z = \frac{f(x^*) - \mu(x)}{\sigma(x)} \end{cases} \quad (14)$$

其中, $f(x^*)$ 为当前最优的目标函数值; $\phi(\cdot)$ 为标准正态分布的累积分布函数; $\Phi(\cdot)$ 为标准正态分布的概率密度函数。

对于每个候选的熵损失系数 ω , 计算期望提升, 再根据期望提升, 选择使得期望提升最大的候选熵

损失系数 ω_{t+1} 。

5) 迭代优化

优化过程将不断迭代进行, 直到训练结束。每次迭代, 贝叶斯优化器会根据当前策略的表现更新熵损失系数 ω , 并重新评估新的回报, 最终优化到最优的熵损失系数, 从而提高策略的总体表现。整体优化流程如图 3 所示。




图 3 算法优化流程

3 实验分析

3.1 实验概述

本实验在 Ubuntu22.04 系统中利用 TensorFlow 框架对本文构建的模型进行训练, 在配置有 NVIDIA GeForce RTX 4090D 型号的显卡上进行。利用 MuJoCo 物理引擎构建了仿真环境, 仿真环境如图 4 所示, 通过对机械臂进行不断的训练和测试, 可以获得其平均奖励的奖励曲线, 从而直观地展示训练算法的效果与性能。




图 4 MuJoCo 中的环境布置

本研究的所有算法都是基于原生的 PPO 算法,故原生 PPO 算法的参数至关重要,为保证原生 PPO 算法的稳定性,通过测试记录奖励函数,选择训练效果较为稳定的一组参数作为本实验中的基准参数,其参数如表 1 所列。

表 1 参数设置

参数名称	数值
Actor 网络学习率	0.0003
Critic 网络学习率	0.0003
折扣因子	0.99
Batch 大小	64
GAE 平滑参数	0.95
剪切系数	0.2
价值函数系数	0.5
并行环境数量	100
总训练回合数	200
回合最大长度	2500

3.2 奖励函数参数敏感性分析

为验证奖励函数中位置误差权重 α 与控制代价权重 β 的比例对于机械臂抓取训练效果的影响,本小节基于 2.1 节定义的奖励函数框架,对三类典型权重比例进行敏感性分析,明确不同比例的性能差异及最优选择。

根据图 5 所示得出,训练初期,1.0:0.1 权重

因位置误差权重高,受到惩罚最大,且智能体为减误差大幅动作致控制代价高,致使奖励值偏低,而 0.5:0.5 权重因对位置误差和控制代价均衡权衡,故奖励值偏高,0.8:0.2 权重的奖励值处于两者之间;训练中期,1.0:0.1 权重下智能体专注减误差找到有效策略致奖励快速上升,0.8:0.2 权重的智能体奖励上升速度也较为可观,不过稍慢于 1.0:0.1 权重的情况,0.5:0.5 权重因精力分散奖励上升慢;最终收敛时,1.0:0.1 权重虽前期奖励值低下,但在高位置误差权重引导下能精准完成任务,靠高额任务完成奖励弥补前期损失,使奖励函数值最高。结合具体任务需求,1.0:0.1 的权重比例能够引导智能体将绝大部分精力投入到减少位置误差上,从而更好地满足任务要求,提升任务完成质量和效率。




图 5 不同奖励函数权重比例的效果对比

3.3 采集策略性能比较

本节将使用贝叶斯优化的三种常用的采集策略进行对比,分别为:期望提升(Expected Improvement, EI)、置信上界(Upper Confidence

Bound, UCB) 和概率提升 (Probability of Improvement, PI)。最终奖励函数如图 6 所示, UCB 由于过度探索, 在后期出现奖励下降趋势, EI 和 PI 虽然快速收敛并保持稳定, 但 EI 奖励函数相对于 PI 提升了 10.25%。本文采用的期望提升策略作为采集函数可以获得更高的奖励函数以达到抓取需求。




图 6 采集策略对比

3.4 改进的 PPO 算法实验分析

为验证改进 PPO 算法的有效性, 通过将改进的 PPO 算法与固定熵损失系数为过大值、过小值以及固定最优值^[10]的原始 PPO 算法和自适应熵损失系数策略^[11]的 PPO 算法的训练效果进行比较, 实验通过在同一环境中对多个训练轮次下的表现进行评估, 从奖励函数和收敛速度等方面进行综合比较, 其平均奖励曲线如图 7 和 8 所示。




图 7 固定熵系数效果对比




图 8 改进 PPO 算法训练效果对比

分析图 7 可知, 当熵损失系数 $\omega=0.001$ 时, 虽然在训练的初始阶段智能体可以获得奖励较大的动作, 但在中期会陷入局部最优, 并且由于智能体探索能力不足, 使其在陷入局部最优时不能快速跳出, 导致后期无法学的奖励最大的动作。当熵损失系数 $\omega=0.05$ 时, 在训练前期可以获得奖励较大的动作, 但由于过大的熵损失系数强制策略随机化, 打破了新旧策略的平稳过渡, 在中期导致奖励函数崩溃出现了骤降的现象并伴随着 KL 散度的激增。

分析图 8 可知, 改进 PPO 算法凭借贝叶斯优化算法对熵损失系数的动态自适应调整, 能精准平衡训练中的探索与利用, 使奖励值快速提升并维持较高水平, 收敛速度与最终性能均最优; 文献^[11]中的

方法，虽能通过目标函数对比实现系数自适应，但优化策略的全局搜索能力较弱，奖励提升幅度与稳定性次于改进 PPO 算法；固定熵系数为 0.02 的方法因缺乏动态调整机制，无法适应训练过程的复杂变化，探索效率低下，奖励值长期处于较低水平且波动明显。这表明在机械臂训练中，基于贝叶斯优化的自适应熵损失系数策略能显著提升 PPO 算法的学习效率与控制性能，验证了动态参数优化对强化学习算法的重要性。

利用训练好的模型对目标物体进行抓取成功率实验，三种算法的对比指标如表 2 所示，改进 PPO 算法相较于原生 PPO 算法和自适应 PPO 算法，在平均奖励上提升 21.2%、15.5%，在抓取成功率上提升 24%、9%，证明了本文所提出的改进 PPO 算法设计的有效性。

表 2 对比指标

算法	平均奖励	收敛回合	成功率
PPO	-1003.441	128	61%
自适应 PPO	-935.907	152	76%
改进 PPO	-790.771	139	85%

3.5 实物实验验证

为验证改进 PPO 算法可行性，搭建了实物测试环境，实验环境中配备了 7 自由度机械臂机器人，并配有 D435 深度相机，位于机器人头部，其视野

覆盖工作区域。所选取的目标物体为矿泉水瓶，并选取本文提出的改进 PPO 算法作为控制算法并部署到真实机器人机械臂上执行相关任务，其抓取流程如图 9 所示。




图 9 实物抓取流程

在实物抓取过程中，机器人通过深度相机 D435 识别目标物体的位置，并将三维坐标传输给下位机。下位机接收到目标信息后，利用本文提出的改进 PPO 算法模型来规划机械臂的抓取路径，并计算每个关节的运动指令。机械臂沿着规划路径运动，末端执行器逐步接近目标，通过改进的 PPO 算法，最终确保夹爪精准抓取。

4 结束语

本文设计并且搭建了机器人机械臂的训练环境，选取 PPO 算法作为机械臂的控制和训练算法。在此环境下，对 PPO 算法进行改进，通过引入贝叶斯优化算法以实现自适应优化熵损失系数，并进行机械臂抓取策略的实验，对改进后的算法进行了测试。

实验结果表明,改进的 PPO 算法的全局概率模型搜索策略能更高效地穿越训练陷阱,规避固定系数导致的探索不足问题,相较于原始 PPO 算法,平均奖励提高了 21.2%,抓取成功率提升了 24%。实验结果不仅为机械臂动态控制提供了更优的算法,更证实了强化学习算法中参数自适应机制对提升控制精度与泛化能力的关键作用,为工业机器人智能控制的工程化应用奠定了坚实的基础。未来研究可进一步结合多目标优化拓展贝叶斯框架,推动算法在多维复杂机械臂任务中的深度落地。

参考文献

- [1] Stuede M , Nuelle K , Tappe S ,et al.Door opening and traversal with an industrial cartesian impedance controlled mobile robot[C]//2019 International Conference on Robotics and Automation (ICRA).2019.
- [2] Chengjun C ,Hao Z ,Yong P , et al.Robot autonomous grasping and assembly skill learning based on deep reinforcement learning[J].The International Journal of Advanced Manufacturing Technology,2024,130(11-12):5233-5249.
- [3] 孔凡国,仇展明,王鑫,等.基于 PPO 算法的机械臂抓取策略研究[J].机电工程技术,2024,53(11):96-100.
- [4] 曹凯,朱勇,高强,等.深度强化学习在自动控制领域研究现状与展望[J].排灌机械工程学报,2023,41(06):638-648.
- [5] Safaoui S , Vinod A P , Chakrabarty A ,et al.Safe multi-agent motion planning under uncertainty for drones using filtered reinforcement learning[J].IEEE Transactions on Robotics, 2023.
- [6] Koh S ,Zhou B ,Fang H , et al.Real-time deep reinforcement learning based vehicle navigation[J].Applied Soft Computing Journal,2020,96
- [7] Li Z ,YaHao W ,Run Y , et al.An Efficiently Convergent Deep Reinforcement Learning-Based Trajectory Planning Method for Manipulators in Dynamic Environments[J].Journal of Intelligent & Robotic Systems,2023,107(4):
- [8] 田成军,颜禹,崔仁伟,等.基于深度强化学习的机械臂自主抓取算法[J/OL].吉林大学学报(工学版),1-9[2025-06-11].
- [9] 周旗龙,陈伟,宋广武,等.基于深度强化学习算法的水下机械臂抓取控制研究[J].自动化与仪表,2025,40(05):62-65+70.
- [10] 王永华,钟欣见,李明.基于改进近端策略优化算法的移动端机械臂抓取实验设计[J].实验技术与管理,2024,41(04):73-80.
- [11] 李锦键,王兴贵,丁颖杰.基于改进 PPO 的 HCSY-MG 并网系统分布式混合储能充放电优化控制[J/OL].电源学报,1-13[2025-05-08].
- [12] Shintani K , Fujimoto T , Okamoto M ,et al.Surrogate modeling of waveform response using singular value decomposition and Bayesian optimization[J].Journal of Advanced Mechanical Design, Systems, and Manufacturing, 2021, 15(2):JAMDSM0018-JAMDSM0018.
- [13] Zhao Y ,Ma D ,Liu W .Efficient Detection of Malicious Traffic Using a Decision Tree-Based

Proximal Policy Optimisation Algorithm: A Deep Reinforcement Learning Malicious Traffic Detection Model Incorporating Entropy[J].Entropy,2024,26(8):648-648.

[14] 朱继伟,张隆源,王冀,等.基于 DRL 和轨迹优化的多机器人导航和编队维护 [J]. 传感器与微系统,2023,42(09):129-132.

[15] Guo Z ,Fu H ,Wu J , et al.Dynamic Task Planning for Multi-Arm Apple-Harvesting Robots Using LSTM-PPO Reinforcement Learning Algorithm[J].Agriculture,2025,15(6):588-588.

[16] Nie J ,Zhang G ,Lu X , et al.Reinforcement learning method based on sample regularization and adaptive learning rate for AGV path

planning[J].Neurocomputing,2025,614128820-128820.

[17] Li- yang Z ,Tian-qing C ,Jie Z , et al.A policy optimization algorithm based on sample adaptive reuse and dual-clipping for robotic action control[J].Applied Soft Computing Journal,2023,134

[18] 周杰,王良明,傅健,等.基于 Hyperband-贝叶斯优化-LSTM 网络的高旋尾控修正弹修正能力研究[J/OL].兵工学报,1-11[2025-05-08].

[19] 张伟国,蒋昆,宋宇,等.基于机器学习和贝叶斯优化的大位移井钻井提速方法 [J/OL]. 石油钻探技术,1-13[2025-05-08].