

基于深度强化学习的机械臂运动学逆解研究*

□ 刘展飞 □ 刘建林

1. 江西现代职业技术学院 智能制造学院 南昌 330095
2. 江西省赣州市兴国县第三中学 江西赣州 342400

摘 要:针对凿岩机器人机械臂逆运动学分析中求解计算量大、函数维度高等问题,对基于深度强化学习的机械臂运动学逆解进行研究。采用改进 Denavit-Hartenberg 法建立机械臂数学模型,并推导正运动学函数。提出一种深度强化学习方法,将神经网络用于优化强化学习参数的配置,减少试错次数。仿真试验表明,深度强化学习能够改善求解速度慢、局部最优解等问题,进而有效对机械臂逆运动学进行求解。

关键词:机械臂 深度强化学习 运动学 逆解

中图分类号: TP241 **文献标志码:** A **文章编号:** 1000-4998(2025)10-0018-04

Abstract: To address the issues of high computational complexity and high-dimensional function in the inverse kinematic analysis of robotic arm in rock drilling robot, the inverse kinematic solution of robotic arm based on deep reinforcement learning was studied. The improved Denavit-Hartenberg method was employed to establish the mathematical model of robotic arm, and the forward kinematic function was derived. A deep reinforcement learning approach was proposed, which utilizes the neural network to optimize the configuration of reinforcement learning parameter and reduce the trial-and-error times. The simulation experiment has shown that deep reinforcement learning can improve the problems of slow solving speed and local optimal solution, thereby effectively solving the inverse kinematic of robotic arm.

Keywords: Robotic Arm Deep Reinforcement Learning Kinematic Inverse Solution

1 研究背景

传统矿道开采作业中,矿石的岩层走向各异,凿岩钎杆的开采姿态需要进行相应调整,开采设备需要满足一定的姿态与推进需求,由此会牺牲末端执行机构的三个自由度进行姿态调整,同时还需要具有快速移动定位的功能。传统六自由度工业机械臂在牺牲三个自由度后,剩余关节移动作业的调整空间严重受限,易发生墙体碰撞或与其他机械臂互相干涉。对此,亟需更高自由度来解决灵巧度问题。

凿岩机器人是一种专门应用于隧道建设与矿井开采领域的凿岩机械设备,依托钻爆法开展作业^[1],具备可移动作业及多台机控台车协同作业的能力,凭借独特的七自由度机械臂,在众多工程应用中已广受赞誉。当然,关节数量增多意味着运动控制难度增大,冗余关节使一个目标位置存在无数个组合解。传统手动控制过度依赖操作员经验判断,需要大量时间进行作业调

整,会严重影响开采作业速度。要实现机械臂开采智能控制,对机械臂的运动学求解是核心。机械臂运动学研究从机械臂末端笛卡尔坐标到关节空间的对应关系,是开展机器人运动控制、轨迹规划、避障路径规划分析等研究工作的重要理论基础。如何求解冗余机械臂运动学逆解,是广大学者聚焦的课题。传统求解方法主要包括封闭解法和数值解法^[2-3]。封闭解法仅适用于结构简单或自由度较低的机械臂逆解问题,对于高自由度的冗余机械臂并不适用,此时只能采用数值解法。在数值解法中,常见的主要有雅可比矩阵迭代法^[4-5]、神经网络法^[6]等。

梁相龙等^[7]针对六关节机械臂提出结合解析法与偏微分理论的计算法,有效减小位置误差,但计算量很大,无法递推至七关节求解。黄开启等^[8]将改进灰狼优化算法应用至逆运动求解,但优化算法的不稳定性使实际应用仍然存疑。张道德等^[9]提出一种基于旋量理论和微分流形理论的求解方法,对强耦合七关节机

* 江西现代职业技术学院校级课题(编号:JXXD-2024-41)

机械臂进行求解,但本质上未摆脱几何法的弊端,存在大量高维度矩阵推导,计算难度大。吴江等^[10]提出一种考虑安全约束的无监督学习型神经网络法对逆运动学求解,但无监督学习需要花费大量时间进行训练和修改参数,不具备工程应用的条件。

近年来,人工智能技术的发展给求解高维函数带来新的启发。强化学习作为一种机器学习技术,旨在使智能体学会如何与环境互动,以最大化长期累积的奖励^[11-12]。传统强化学习在处理维度较低的状态和动作空间时表现出色,但在大数据时代,面对高维数据输入,能力受到限制。为了改变算法缺陷,将深度学习中的卷积神经网络融入强化学习,提出深度强化学习算法,标志着深度强化学习的诞生^[13]。


深度强化学习结合深度学习的特征抽取能力和强化学习的决策能力,使智能体能够直接从多维输入数据中提取有用信息,并据此做出最优决策。笔者针对机械臂高维度函数计算问题,采用深度强化学习对凿岩机器人七关节机械臂进行求解,将机械臂的环境信息与动作信息导入智能体,智能体通过学习试错,给出最佳的关节角度参数,并且通过仿真软件进行可行性测试。

2 凿岩机械臂运动学模型

某型号凿岩台车的凿岩机械臂结构如图1所示。关节1为大臂偏摆关节,可在水平面上左右偏转。关节2为大臂俯仰关节,可在竖直平面内实现俯仰。关节3为大臂延伸关节,负责机械臂伸长缩短。关节4为推进器翻转关节,可调整钻杆的上下位置。关节5、6分别为推进器俯仰和偏摆关节,负责开采姿态调整。关节7为推进器推进关节,可将钎杆送入炮孔。机械臂采用液压驱动。为构建机械臂运动学模型,将其抽象为由七个独立关节依次串联而成的连杆系统,理想状态下各关节间无运动耦合干扰。为了清晰表征各关节之间的雅可比空间几何关系,选用改进型 Denavit-Hartenberg 法进行建模,通过雅可比矩阵推导机械臂的正向运动学方程,得出从关节空间至操作空间的精确映射,最终获得机械臂末端执行器的空间位姿正解。

图1中省略的各关节Y轴坐标方向可由右手定则推导。 $x_0y_0z_0$ 为基坐标系, $x_1y_1z_1 \sim x_7y_7z_7$ 为关节1~7的关节坐标系。Denavit-Hartenberg 参数见表1。表1中, $q_1、q_2、q_4、q_5、q_6$ 依次为关节1、2、4、5、6未定义关节转角参数, $q_3、q_7$ 分别为关节3、7未定义关节偏移参数, θ 为关节转角, d 为关节偏移, a 为连杆长度, α 为连杆转角, o_{ffset} 为关节初始偏置。

采用 MATLAB 平台对机械臂进行建模仿真,根据 Denavit-Hartenberg 参数,构建正向运动学模型,采用4



▲图1 凿岩机械臂结构

表1 Denavit-Hartenberg 参数

关节	关节类型	$\theta/(^{\circ})$	d/mm	a/mm	$\alpha/(^{\circ})$	$o_{\text{ffset}}/(^{\circ})$
1	旋转	q_1	70	190	0	0
2	旋转	q_2	0	200	-90	-90
3	平移	0	q_3	0	-90	0
4	旋转	q_4	666	0	0	0
5	旋转	q_5	632	0	90	90
6	旋转	q_6	145	585.3	90	-90
7	平移	-90	q_7	-257.5	-90	0

$\times 4$ 矩阵描述关节位姿,进行坐标系齐次变换。姿态描述矩阵通用式为:

$$T_n = \begin{bmatrix} C_{\theta_i} & -S_{\theta_i} & 0 & \alpha_{i-1} \\ S_{\theta_i}C_{\alpha_{i-1}} & C_{\theta_i}C_{\alpha_{i-1}} & -S_{\alpha_{i-1}} & -S_{\alpha_{i-1}}d_i \\ S_{\theta_i}S_{\alpha_{i-1}} & C_{\theta_i}S_{\alpha_{i-1}} & C_{\alpha_{i-1}} & C_{\alpha_{i-1}}d_i \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (1)$$

式中: T_n 为坐标系 n 相对于坐标系 $n-1$ 的齐次变换矩阵; i 为机械臂关节序号; S_{θ_i} 为关节 i 的关节转角正弦函数值; C_{θ_i} 为关节 i 的关节转角余弦函数值; $S_{\alpha_{i-1}}$ 为关节 $i-1$ 的连杆转角正弦函数值; $C_{\alpha_{i-1}}$ 为关节 $i-1$ 的连杆转角余弦函数值; α_{i-1} 为关节 i 的连杆转角; d_i 为关节 i 的关节偏移。

将 Denavit-Hartenberg 参数代入式(1),可得机械臂各关节之间的坐标变换矩阵。经过反复推导计算,得到机械臂末端位姿矩阵 T_{70} 表达式,为:

$$T_{70} = T_1 T_2 T_3 T_4 T_5 T_6 T_7 = \begin{bmatrix} n_{7x} & o_{7x} & a_{7x} & P_{70x} \\ n_{7y} & o_{7y} & a_{7y} & P_{70y} \\ n_{7z} & o_{7z} & a_{7z} & P_{70z} \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (2)$$

式中: $T_1 \sim T_7$ 为关节1~7的末端位姿矩阵表达式; n_{7x} 为关节7的 x 轴法向量; n_{7y} 为关节7的 y 轴法向量; n_{7z} 为关节7的 z 轴法向量; o_{7x} 为关节7的 x 轴滑动矢量; o_{7y} 为关节7的 y 轴滑动矢量; o_{7z} 为关节7的 z 轴滑动矢量; a_{7x} 为关节7的 x 轴接近矢量; a_{7y} 为关节7的 y 轴接近矢量; a_{7z} 为关节7的 z 轴接近矢量; P_{70x} 为目标点相对于原点坐标的三维空间 x 轴坐标; P_{70y} 为目标点相

对于原点坐标的三维空间 y 轴坐标; P_{70z} 为目标点相对于原点坐标的三维空间 z 轴坐标。

3 深度强化学习算法

3.1 数学建模

将机械臂目标点与当前位置的误差作为输入,通过七个关节的参数搜索,将最接近目标点的机械臂参数作为寻优对象,建立机械臂末端位姿与目标位姿之间的误差函数,为:

$$f(x_i) = p(x_i) - p_{obj} \quad (3)$$

式中: $f(x_i)$ 为位置 x_i 所对应的一组参数解的适应度值; $p(x_i)$ 为粒子在位置 x_i 时所对应的位姿状态; p_{obj} 为目标位姿状态。

通过智能体对空间的强化学习搜索,将逆解搜索转换为误差最小值求解,实现对机械臂逆运动学问题的有效求解。

3.2 逆运动学求解流程

常用的强化学习算法在进行机械臂连续动作空间求解时,会遭遇维度灾难和计算量超负荷问题。对此,提出采用卷积神经网络拟合强化学习最优参数搜索,减少强化学习的试错次数,以形成深度强化学习算法。深度强化学习算法可以深入分析动作数据,为每个目标点输出对应的预期累计奖励 Q 。预期累计奖励 Q 可表示为:

$$Q(s, A) \leftarrow r_j + r_A' Q(s_{j+1}, A_{j+1}'; \theta^-) \quad (4)$$

式中: s 为状态; A 为动作; $Q(s, A)$ 为当前状态和当前动作的 Q 值; r_j 为第 j 轮的环境奖励值; r_A' 为采取动作的奖励值; $Q(s_{j+1}, A_{j+1}'; \theta^-)$ 为下一个状态的 Q 值; s_{j+1} 为第 $j+1$ 轮的状态; A_{j+1}' 为第 $j+1$ 轮的目标动作; θ^- 为目标神经网络中的参数。

神经网络输出是对 Q 值的近似解,目标在于取得最优逆解时的 Q 值,以缩短试错时间,并减少迭代次数。在训练过程中,通过反向传播和梯度下降等方法实时更新神经网络的参数 θ ,使损失函数达到最小化,提高深度强化学习算法的求解准确性。损失函数 l_{oss} 的表达式为:

$$l_{oss} = E[(y_j - Q(s_j, A_j; \theta))^2] \quad (5)$$

式中: E 为损失期望值; y_j 为第 j 轮目标神经网络的 Q 值; s_j 为第 j 轮的状态; A_j 为第 j 轮的动作。

$$y_j = r_j + \gamma \max_{A_{j+1}} Q(s_{j+1}, A_{j+1}; \theta^-) \quad (6)$$


式中: γ 为折扣因子; $\max_{A_{j+1}} Q(s_{j+1}, A_{j+1}; \theta^-)$ 为选择下一步状态中奖励最大的 Q 值; A_{j+1} 为第 $j+1$ 轮的动作。

采用梯度下降法更新网络参数 θ ,为:

$$\theta \leftarrow \theta + \beta E[(r_j + \gamma \max_{A_{j+1}} Q(s_{j+1}, A_{j+1}; \theta^-) - Q(s, A; \theta)) \nabla_{\theta} Q(s, A; \theta)] \quad (7)$$

式中: β 为学习率; ∇_{θ} 为对 θ 求一阶导。

深度强化学习算法网络结构如图2所示。在决策部分,加入经验回放环节,提高每一轮的有效探索率。深度强化学习算法将智能体探索过程中产生的每一步探索数据存储在一个小型经验池中,在训练过程中,深度强化学习算法从经验池中随机抽取小批量样本更新网络参数,使新旧经验混合利用,得到一定的学习率。最后引入目标网络,解决非线性函数对 Q 值拟合出现的不稳定与振荡情况,并采用目标网络评估下一个状态的 Q 值。通过损失函数计算,同时采用梯度下降的方法更新函数网络的权重参数,进而更新目标网络的参数,直到网络的求解性能达到预定精度为止。



▲图2 深度强化学习算法网络结构

奖励函数的优劣对学习网络至关重要,奖励值太低,可能导致搜索无解,奖励值太高,容易出现局部最优解现象。设置的奖励函数为:

$$R = R_s + R_g + R_t \quad (8)$$

式中: R 为奖励; R_s 为步数惩罚,旨在获得最短路径; R_g 为目标奖励; R_t 为柔顺度惩罚。

由于逆运动学求解维度高,计算量大,因此可适当减小步数惩罚和增大目标奖励。笔者增加最佳柔顺度评价标准,使求解满足基于当前状态的最小偏移量,避免陷入多解状态。


4 仿真试验

采用 MATLAB 平台建立七关节机械臂的运动学模型,硬件设备采用视窗 10 系统,处理器型号为锐龙 2600,软件版本为 MATLAB 2024a。将模型导入环境,机械臂末端初始位姿坐标为(9 343.3 mm,889.5 mm,215 mm),假设目标位姿坐标为(10 000 mm,900 mm,230 mm),同时考虑位置误差与姿态误差,将两种误差相加,取最小值解为最优参数。通过深度强化学习算法求解,最大回合数为 1 000,最大步长 3 000,探索利用比例为 1,运行五次后得到各关节参数求解结果,见表 2。运行五次后迭代收敛情况如图 3 所示,最优求解结果如图 4 所示。


由图3、图4可以看出,运行五次后,基于深度强

表2 各关节参数求解结果

运行次数	位置误差/mm	姿态误差/mm	迭代次数	耗时/s
1	0.008 7	0.108 2	116	0.517 834
2	$2.273\ 7 \times 10^{-13}$	$2.669\ 3 \times 10^{-4}$	95	0.277 922
3	$4.951\ 6 \times 10^{-7}$	$4.166\ 2 \times 10^{-6}$	49	0.149 089
4	$1.231\ 6 \times 10^{-6}$	0.182 2	44	0.136 856
5	$1.289\ 7 \times 10^{-8}$	0.164 6	50	0.150 803



▲图3 迭代收敛情况



▲图4 最优求解结果

化学习算法对机械臂逆运动学有较好的求解收敛性,最快收敛次数仅为44,具有较快的求解速度。在五次求解过程中,理论上最优位姿误差为 2.27×10^{-13} mm。将求解参数输入示教器,由于输出坐标参数显示精度自身存在一定误差,求解位姿误差为0.693 4 mm,已经符合实际工况应用要求,具有优秀的求解性能。

5 结束语

笔者对七关节机械臂进行建模,有效推导正运动学函数。采用卷积神经网络,对预期累计奖励 Q 进行优化。对机械臂逆运动学求解,通过MATLAB平台进行仿真试验。通过研究,得出深度强化学习算法能够有效解决强化学习对高维度函数求解计算维度灾难问题,并可以对机械臂逆运动学各关节参数进行有效求

解,具有实际应用价值。当然,笔者研究仅为理想状态下的机械臂运动学,并未对材料属性进行分析,机械臂自身质量带来的物理偏差未融入模型。深度强化学习算法求解速度因设备而异,在实际应用中,还需提高收敛速度,缩短搜索时间。在后续研究工作中,可以将机械臂模型导入智能体,增加碰撞惩罚,用于空间避障轨迹规划。

参考文献

- [1] 洪开荣. 中国大陆典型水下隧道工程案例与技术[J]. Engineering, 2017, 3(6): 196-213.
- [2] SINGH G K, CLAASSENS J. An Analytical Solution for the Inverse Kinematics of a Redundant 7DoF Manipulator with Link Offsets[C]// 2010 IEEE/RSJ International Conference on Intelligent Robots and Systems, Taipei, 2010.
- [3] 张栩曼, 张中哲, 王燕波, 等. 基于空间六自由度机械臂的逆运动学数值解法[J]. 导弹与航天运载技术, 2016(3): 81-84.
- [4] BUSS S R. Introduction to Inverse Kinematics with Jacobian Transpose, Pseudoinverse and Damped Least Squares Methods[R]. 2004.
- [5] 王腾, 张承瑞, 陈齐志, 等. 利用增广雅克比矩阵的冗余机械臂逆运动学求解算法[J]. 科学技术与工程, 2021, 21(16): 6752-6757.
- [6] 田文杰. 融合多尺度波动散布熵与深度学习的液压泵节能控制[J]. 机械制造, 2025, 63(5): 9-13.
- [7] 梁相龙, 姚志凯, 邓文翔, 等. 六自由度液压机械臂运动学标定和逆解研究[J]. 机械工程学报, 2025, 61(2): 346-357.
- [8] 黄开启, 刘展飞, 陈翀, 等. 基于烟花灰狼算法的冗余机械臂运动学逆解[J]. 机床与液压, 2023, 51(15): 141-147.
- [9] 张道德, 何嘉懿, 王君明. 凿岩机械臂逆运动学解流形分析及优化[J]. 机床与液压, 2024, 52(21): 28-34, 51.
- [10] 吴江, 许皓渊, 闫昊琪, 等. 无监督学习型凿岩钻臂逆运动学求解方法[J]. 工程科学学报, 2024, 46(8): 1479-1488.
- [11] 谭靖, 杨利刚, 李潇睿, 等. 深度强化学习及其在工业场景的应用与展望[J]. 工程科学学报, 2025, 47(4): 768-779.
- [12] 赵恬恬. 基于深度强化学习的无人机路径规划研究[D]. 德阳: 中国民用航空飞行学院, 2024.
- [13] SUTTON R S, BARTO A G, et al. Reinforcement Learning: An Introduction[M]. Cambridge: MIT Press, 1998.

收稿时间: 2025-06

作者简介:

刘展飞(1997—),男,助教,主要研究方向为凿岩机器人智能控制、人工智能;刘建林(1983—),男,高级教师,主要研究方向为智能控制。(编辑 岚)