

# 基于增强深度拉格朗日神经网络的机械臂系统辨识

Mechanical Arm System Identification Based on Enhanced Deep Lagrangian Neural Network

朱纪辉 (华中科技大学人工智能与自动化学院, 湖北 武汉 430074)

**摘要:** 机械臂是工业自动化领域中的重要执行部件,而精确的动力学模型对于机械臂的高精度控制至关重要。传统的基于线性化模型的辨识方法缺乏非线性处理的能力。近年来,基于深度拉格朗日神经网络(DeLaN)的多体建模方法,实现了可解释性的广义力建模,但是缺乏包含摩擦力的全面的建模和学习策略。针对这些问题,提出一种结合非线性摩擦力的增强DeLaN系统辨识方法(E-DeLaN),设计了结合正动力学、逆动力学、能量等物理信息的学习策略,进一步提升建模的物理可解释性和建模精度。基于ER3A-C60六轴机械臂平台进行实验,与其他先进方法进行对比,结果表明所提出的辨识方法具有更高的辨识精度。

**关键词:** 工业机械臂;动力学建模;系统辨识;深度拉格朗日神经网络

**Abstract:** An enhanced DeLaN system identification method (E-DeLaN) combining nonlinear friction is proposed, and a learning strategy combining positive dynamics, inverse dynamics, energy and other physical information is designed to further improve the physical interpretability and modeling accuracy of the modeling. Experiments on ER3A-C60 six-axis manipulator platform are carried out, and compared with other advanced methods, the results show that the proposed identification method has higher identification accuracy.

**Keywords:** industrial mechanical arm, dynamic modeling, system identification, Deep Lagrange neural networks (DeLaN)

随着机械臂柔性化和智能化需求的提升,机械臂的精确控制性能有待进一步提高,而动力学参数的高精度辨识成为了优化控制性能的瓶颈,亟需结合物理规律和数据驱动的新方法以实现更精确的模型构建<sup>[1]</sup>。综合目前最新的机械臂系统辨识方法,主要存在如下问题:首先,基于模型的辨识方法基于刚体假设,且缺乏非线性处理能力,无法处理机械臂的关节柔性;其次,目前很少有辨识策略考虑到速度过零时的摩擦力建模问题,导致在速度切换时都存在较大的力矩拟合误差。最后,基于数据驱动以及物理神经网络的辨识算法研究较少,还存在较大提升空间,目前并没有同时考虑逆动力学和正动力学物理特性的辨识方法。

针对以上挑战,本文提出一种新的基于深度拉格朗日神经网络框架(DeLaN)的工业机械臂参数辨识方法。

## 1 机械臂动力学建模

### 1.1 拉格朗日动力学

拉格朗日是经典力学的一种理论框架,它通过系统的能量(动能和势能)而非传统的力来分析运动。特别适用于复杂多体系统动力学建模。拉格朗日量为:

$$L=T-V \quad (1)$$

其中, $T$ 为系统的动能, $V$ 表示系统的势能。其中 $T$ 可以表示为:

$$T=\frac{1}{2}\dot{q}^T H(q)\dot{q} \quad (2)$$

其中, $H(q)$ 表示惯性矩阵,其满足正定对称特性,正定性保证了所有非零的速度都会产生正动能。通过最小作用量原理(变分法),推导出系统的运动方程:

$$\frac{d}{dt}\left(\frac{\partial L}{\partial \dot{q}_i}\right)-\frac{\partial L}{\partial q_i}=\tau_i, (i=1,2,\dots,n) \quad (3)$$

其中 $\tau_i$ 表示拉格朗日广义力矩。

将式(1)、(2)、(3)结合起来,得到机械臂的拉格朗日动力学模型:

$$H(q)\ddot{q}+\dot{H}(q)\dot{q}-\frac{1}{2}\left(\frac{\partial}{\partial q}\left(\dot{q}^T H(q)\dot{q}\right)\right)^T+\frac{\partial V}{\partial q}=\tau \quad (4)$$

其中, $\dot{H}(q)\dot{q}-\frac{1}{2}\left(\frac{\partial}{\partial q}\left(\dot{q}^T H(q)\dot{q}\right)\right)^T=C(q,\dot{q})$ 表示离心力与科氏力矩阵, $\frac{\partial V}{\partial q}:=G(q)$ 表示重力矩阵。

引入摩擦力和噪声之后,动力学模型表示为:

$$H(q)\ddot{q}+\dot{H}(q)\dot{q}-\frac{1}{2}\left(\frac{\partial}{\partial q}\left(\dot{q}^T H(q)\dot{q}\right)\right)^T+\frac{\partial V}{\partial q}+\tau_f+\tau_{err}=\tau \quad (5)$$

此时, $\tau$ 表示关节驱动力矩, $\tau_f$ 表示关节摩擦力矩, $\tau_{err}$ 表示力矩误差。式(5)即为机械臂的逆动力学方程。

### 1.2 摩擦力建模方法

在机械臂参数辨识中,最常用的两种摩擦力建模方法分别为线性库伦-黏滞摩擦模型和非线性Stribeck模型。两者摩擦模型分别表示为:

1)库伦-黏滞摩擦模型:

$$\tau_{f,i}=f_{c,i}\text{sign}(\dot{q}_i)+f_{v,i}\dot{q}_i \quad (6)$$

其中, $i$ 为关节轴序号, $f_{c,i}$ 为库伦摩擦系数, $f_{v,i}$ 为黏性摩擦系数。

2)Stribeck摩擦模型:

$$\tau_{f,i}=f_{v,i}\dot{q}_i+\text{sign}(\dot{q}_i)(f_{c,i}+(f_{s,i}-f_{c,i})e^{-\left(\frac{|\dot{q}_i|}{v_s}\right)^{\delta_s}}) \quad (7)$$

其中, $f_{c,i}$ 库伦摩擦系数, $f_{s,i}$ 为静摩擦力系数, $v_s$ 为Stribeck速度,决定了Stribeck效应发生的速度范围, $\delta_s$ 为指数因子,控制摩擦力随速度大小减小的速率, $f_{v,i}$ 为黏性摩擦系数。

### 1.3 DeLaN建模框架

DeLaN<sup>[2]</sup>是一种基于物理信息神经网络的新型动力学建模框架,将常微分拉格朗日动力学方程(ODE)整合到网络结构中,以端到端的形式学习参数,提高模型的收敛速度和泛化能力。

DeLaN使用深度神经网络来近似式(4)中的 $H$ 和 $V$ :

$$\hat{H}=\hat{L}(q;\theta)\hat{L}^T(q;\theta)+\varepsilon I \quad (8)$$

$$\hat{V}=\hat{V}(q;\phi) \quad (9)$$

式(8)中, $L$ 是具有非负对角线的下三角矩阵, $\varepsilon$ 为一个非常小的

正常数, 惯性矩阵  $H$  可以确保为正定, 最小特征值为  $\varepsilon_0$ .  $\theta$  和  $\varphi$  表示网络参数. 通过最小化拉格朗日 ODE 方程的误差, 从数据中端到端地学习网络参数:

$$(\theta^*, \varphi^*) = \operatorname{argmin}_{\theta, \varphi} J(f^{-1}(q, \dot{q}, \ddot{q}; \theta, \varphi), \tau) + \lambda \Omega(\theta, \varphi) \quad (10)$$

其中,  $f^{-1}$  代表系统的逆动力学模型,  $J$  代表网络的损失函数.  $\Omega$  表示参数  $\theta$  的正则化项.

DeLaN 的大体框架中, 网络的输入为关节的运动信息(角度、角速度、角加速度), 网络的输出为  $H$ 、 $C$ 、 $G$ 、力矩等.

将矩阵  $L$  分解为对角矩阵  $L_d$  和严格下三角矩阵  $L_o$ , 使用 ReLU 激活函数保证  $L_d$  中元素的非负性.

对于摩擦力的部分, 可以将摩擦力系数作为网络参数参与训练, 可以实现和广义动力学的同步收敛.

## 2 增强 DeLaN 辨识算法

本文所提出的增强 DeLaN 算法(E-DeLaN)框架如图 1 所示, 相比较于标准的 DeLaN 算法, 主要有以下几点改进:

1) 针对摩擦力的非线性特性和速度过零时的摩擦力连续特性, 改进 Stribeck 摩擦力模型以提升摩擦力拟合效果.

2) 在 DeLaN 框架中, 引入正动力学误差和系统能量误差作为损失函数的一部分, 并设计归一化损失函数来应对不同关节的不同力矩范围以及更好地融合多种物理信息损失.




图 1 增强 DeLaN 框架图

### 2.1 引入非线性摩擦力

有研究表明<sup>[3]</sup>, 机械臂摩擦力矩在速度过零时呈现连续特性, 这是库伦-黏滞摩擦模型和 Stribeck 模型所不能表示的, 为了体现摩擦力矩速度过零时的连续性, 本文修改 Stribeck 模型如下:

$$\tau_{f,i} = f_{c,i} \tanh(\alpha_i \dot{q}_i) + f_{v,i} \dot{q}_i + \tanh(\beta_i \dot{q}_i) (f_{s,i} - f_{c,i}) e^{-\left(\frac{|\dot{q}_i|}{V_{s,i}}\right)^{\delta_{s,i}}} \quad (11)$$

该摩擦模型引入速度向的双曲正切函数, 保留了低速区的 Stribeck 效应以及高速区的黏滞效应, 并且保证了速度过零时的摩擦力连续特性, 相比较 Stribeck 模型, 只增加了参数  $\alpha$  和  $\beta$ .

所以摩擦力相关参数一共包括  $f_{c,i}$ 、 $f_{s,i}$ 、 $V_{s,i}$ 、 $\delta_{s,i}$ 、 $f_{v,i}$ 、 $\alpha_i$ 、 $\beta_i$ . 将这些参数作为神经网络的参数, 并使用 SoftPlus 函数约束参数的非负性. 在训练过程中通过最小化损失函数从而逐渐学习这些参数的值.

### 2.2 引入正动力学方程

DeLaN 辨识框架相比较传统辨识算法以及数据驱动辨识算法不同的一点是, DeLaN 的辨识结果为惯性矩阵  $H$  和势能  $V$ , 其辨识结果可以直接用于 MPC 等基于模型的控制算法中. 对于此类控制算法, 其往往需要通过机械臂系统的当前输入和状态来求取加速度信息, 对应正动力学:

$$\ddot{q} = f(q, \dot{q}, \tau; \theta, \varphi) \quad (12)$$

为了获取更精确的加速度估计值, 引入正动力学到网络结构中, 损失函数修改为:

$$(\theta^*, \varphi^*) = \operatorname{argmin}_{\theta, \varphi} J_1(\hat{f}^{-1}(q, \dot{q}, \ddot{q}; \theta, \varphi), \tau) + J_2(\hat{f}(q, \dot{q}, \tau; \theta, \varphi), \ddot{q}) + \lambda \Omega(\theta, \varphi) \quad (13)$$

为了应对机械臂不同关节力矩范围不同, 以及更好地融合不同物理信息, 使用对均方误差进行归一化处理, 损失函数  $J_1$  和  $J_2$  分别定义为:

$$J_1(\tau, \tau) = \frac{1}{6} \sum_{j=1}^6 \frac{\sum_{i=1}^n (\tau_{i,j} - \hat{\tau}_{i,j})^2}{\sum_{i=1}^n \tau_{i,j}^2} \quad (14)$$

$$J_2(\ddot{q}, \ddot{q}) = \frac{1}{6} \sum_{j=1}^6 \frac{\sum_{i=1}^n (\ddot{q}_{i,j} - \hat{\ddot{q}}_{i,j})^2}{\sum_{i=1}^n \ddot{q}_{i,j}^2} \quad (15)$$

其中,  $\hat{\tau}_{i,j}$ 、 $\hat{\ddot{q}}_{i,j}$  分别表示第  $i$  个关节轴第  $j$  个采样点的力矩估计值和实际值,  $\ddot{q}_{i,j}$ 、 $\hat{\ddot{q}}_{i,j}$  分别表示第  $i$  个关节轴第  $j$  个采样点的加速度估计值和实际值.

2.3 引入能量守恒方程

除了拉格朗日力学的 ODE 方程外, 机械臂系统还需遵循能量守恒定律. 系统的能量总和等于动能加上势能, 同时也等于初始时刻系统的能量加上非保守力做的功, 系统在  $t$  时刻的总能量如式(16)所示:

### 2.3 引入能量守恒方程

除了拉格朗日力学的 ODE 方程外, 机械臂系统还需遵循能量守恒定律. 系统的能量总和等于动能加上势能, 同时也等于初始时刻系统的能量加上非保守力做的功, 系统在  $t$  时刻的总能量如式(16)所示:

$$E(t) = T(t) + V(t) = E_0 + W_m(t) - E_f(t) \quad (16)$$

其中,  $E_0$  表示初始时刻的系统能量,  $W_m$  表示关节电机产生扭矩所做的功,  $E_f$  代表由于摩擦力产生的能量损耗.

由关节扭矩所作的功可以表示为:

$$W_m(t) = \int_{q(0)}^{q(t)} \tau^T(q) dq = \int_0^t \tau^T(q(u)) \dot{q}(u) du \quad (17)$$

同理, 摩擦力所作的功可以表示为:

$$W_f(t) = \int_{q(0)}^{q(t)} \tau_f^T(q) dq = \int_0^t \tau_f^T(q(u)) \dot{q}(u) du \quad (18)$$

对式(16)进行微分, 得到能量的变化率为:

$$\dot{E} = \dot{q}^T (\tau - \tau_f) = \dot{T} + \dot{V} = \dot{q}^T H \ddot{q} + \frac{1}{2} \dot{q}^T H \dot{q} + \dot{q}^T \frac{\partial V}{\partial q} \quad (19)$$

辨识过程中我们只能通过电机反馈获取真实的电机力矩  $\tau$ , 将式(17)重新表示为:

$$\dot{W}_m = \dot{q}^T \tau \quad (20)$$

$$\dot{W}_m = \dot{T} + \dot{V} + \dot{q}^T \tau_f \quad (21)$$

引入能量之后, 损失函数修改为:

$$(\theta^*, \varphi^*) = \operatorname{argmin}_{\theta, \varphi} J_1(\hat{f}^{-1}(q, \dot{q}, \ddot{q}; \theta, \varphi), \tau) + J_2(\hat{f}(q, \dot{q}, \tau; \theta, \varphi), \ddot{q}) + J_3(\dot{W}_m, \dot{W}_m) + \lambda \Omega(\theta, \varphi) \quad (22)$$

其中, 定义损失函数  $J_3$  为:

$$J_3(\dot{W}_m, \dot{W}_m) = \frac{\sum_{j=1}^n (\dot{W}_{m,j} - \hat{\dot{W}}_{m,j})^2}{\sum_{j=1}^n \dot{W}_{m,j}^2} \quad (23)$$

其中,  $\dot{W}_{m,j}$  和  $\hat{\dot{W}}_{m,j}$  分别表示第  $j$  个采样点的电机扭矩做功的变化率.

## 3 实验

### 3.1 实验平台搭建

本文实验平台基于埃夫特六轴机械臂 ER3A-C60, 机械臂实物图如图 2 所示. 基于先焔 HPM6750 芯片搭建微控制器, 主

频 800 MHz。伺服驱动采用日鼎伺服 GHA-E,支持作为 EtherCAT 从站运行。软件部分基于 RT-Thread 操作系统实现线程管理,基于 EtherCAT 协议提供高速通信,基于 CANOpen 协议和 CiA402 协议提供标准化运动控制。控制器基于 TCP 和上位机通信,实时反馈机械臂各关节的运动信息(反馈位置、反馈速度、反馈力矩)。位置和速度根据电机减速比和脉冲数转化来计算,力矩根据额定力矩的千分比计算。




图2 ER3A-C60 六轴机械臂实物图

3.2 系统辨识实验

设计五阶傅里叶级数激励轨迹,并采用通用方法求取满足约束条件的激励轨迹,并添加末端操作空间约束条件,确保机械臂不会与实验台面发生碰撞<sup>[4]</sup>。机械臂第  $i$  个关节的运动轨迹表示为:

$$q_i(t)=q_{i,0}+\sum_{k=0}^5\frac{a_{i,k}}{k\omega_i}\sin(k\omega_it)-\frac{b_{i,k}}{k\omega_i}\cos(k\omega_it)\tag{24}$$

基频  $\omega_i$  设置为 0.2,以条件数为优化目标使用遗传算法进行优化。选取优化后的激励轨迹进行数据采样,并与文献<sup>[5-6]</sup>算法进行对比,如表 1 所示:

表 1 辨识方法比较

| 方法                 | 类型              | 实现                                             |
|--------------------|-----------------|------------------------------------------------|
| 方法一 <sup>[5]</sup> | 基于模型的辨识方法       | 融合 Stribeck 摩擦模型和物理可行性约束,使用迭代加权最小二乘进行惯性参数辨识    |
| 方法二 <sup>[6]</sup> | 基于物理信息神经网络的辨识方法 | 将 Stribeck 模型融入 DeLaN 框架中,进行动力学和摩擦的同步辨识        |
| E-DeLaN (本文所提方法)   | 基于物理信息神经网络的辨识方法 | 将正动力学、能量守恒融入 DeLaN 框架中,并改进 Stribeck 摩擦模型去拟合摩擦力 |

基于 1 kHz 的控制频率对机械臂进行运动控制和数据采样。对收集到的运动数据进行滤波处理,通过巴特沃斯滤波器进行正反向滤波,以抵消滤波带来的相位误差,选用巴特沃斯滤波器的阶数为 4 阶,截止频率为 20 Hz。通过微分求取速度和加速度。

方法 Hybrid-PINN 和 Enhanced-DeLaN 均采用相同的激励轨迹作为训练数据,一共采取 12 条五阶傅里叶级数训练轨迹。两者采用相同的网络结构,网络隐藏层数为 3 层,每层神经元个数为 128,以  $1e-4$  的学习率,基于 Adam 优化器进行 8000 次训练,两个算法均已达到收敛。几种方法均采用同一验证轨迹。三个算法都以 1:100 的比例进行亚采样,提高辨识和网络收敛的效率。各算法的交叉验证结果如图 3 和图 4 所示。




图 3 六轴机械臂参数辨识力矩拟合结果

从图 3 和图 4 中可以看出,相较于模型辨识方法一和基于 PINN 的辨识方法二,本文所提出的 E-DeLaN 具有更低的力矩预测误差,尤其在速度过零时的低速区间内,E-DeLaN 的预测误差相对于前两种算法大大降低,可以较准确地拟合 Stribeck 效应和速度过零时的摩擦力连续特性。




图 4 六轴机械臂参数辨识力矩拟合误差

为更直观地比较三种方法的辨识精度,统计三种方法的力矩误差均方根误差(RMSE)和平均绝对值误差(MAE)如表 2 所示。E-DeLaN 算法在均方根误差(RMSE)和平均绝对值误差(MAE)指标上都具有明显优势,相较于方法一和方法二具有更高的辨识精度。

表 2 辨识方法效果比较

| 指标          | 算法      | 轴序号           |               |               |
|-------------|---------|---------------|---------------|---------------|
|             |         | 1             | 2             | 3             |
| RMSE<br>/Nm | 方法一     | 1.1266        | 4.7727        | 1.2419        |
|             | 方法二     | 0.8517        | 1.4435        | 0.5048        |
|             | E-DeLaN | <b>0.1977</b> | <b>0.1625</b> | <b>0.1304</b> |
|             |         | 4             | 5             | 6             |
| MAE<br>/Nm  | 方法一     | 0.6561        | 0.6307        | 0.6668        |
|             | 方法二     | 0.2823        | 0.2652        | 0.4123        |
|             | E-DeLaN | <b>0.1075</b> | <b>0.1640</b> | <b>0.0932</b> |
|             |         | 1             | 2             | 3             |
| MAE<br>/Nm  | 方法一     | 0.7814        | 3.7562        | 0.9359        |
|             | 方法二     | 0.5805        | 0.8614        | 0.3576        |
|             | E-DeLaN | <b>0.1557</b> | <b>0.1159</b> | <b>0.0868</b> |
|             |         | 4             | 5             | 6             |
| MAE<br>/Nm  | 方法一     | 0.4263        | 0.4429        | 0.4743        |
|             | 方法二     | 0.1979        | 0.2145        | 0.2923        |
|             | E-DeLaN | <b>0.0775</b> | <b>0.1021</b> | <b>0.0689</b> |

在配备单个 NVIDIA RTX 3060 Laptop GPU (6 GB) 的笔记本电脑上,计算一次逆动力学所花费的时间平均为 0.0496 ms,满足机械臂实时性控制的需求(控制频率  $\geq 1$  kHz)。

4 结束语

本文提出了一种增强拉格朗日深度神经网络(E-DeLaN)机械臂系统辨识算法,不依赖具体的机械臂构造,构造简单且泛化性强。后续的研究可以集中在更多物理信息的发掘,以及在更高自由度、更复杂机械臂系统上的实现与验证。

参考文献

[1]王昆仑.我国工业机器人产业现状、竞争力及未来发展策略[J].机器人技术与应用,2024(3):8-13

[2]LUTTER M, RITTER C, PETERS J. Deep lagrangian networks: Using Physics as Model Prior for Deep Learning[J]. arXiv preprint arXiv:1907.04490, 2019

[3]刘茂熠.六自由度工业机器人动力学参数辨识方法研究[D].哈尔滨:哈尔滨工业大学,2022

[4]TIAN H Y, HUBER M, MOWER C E, et al. Excitation Trajectory Optimization for Dynamic Parameter Identification Using Virtual Constraints in Hands-on Robotic System[C]// Proceedings of the 2024 IEEE International Conference on Robotics and Automation, 2024: 11605-11611

[5]ZHOU Y F, LI Z C, ZHANG X Y, et al. A Semi-linearized Approach for Dynamic Identification of Manipulator Based on Nonlinear Friction Model[J]. IEEE Transactions on Instrumentation and Measurement, 2024

[6]HU H B, SHEN Z K, ZHUANG C G. A PINN-Based Friction-Inclusive Dynamics Modeling Method for Industrial Robots[J]. IEEE Transactions on Industrial Electronics, 2025, 72(5): 5136-5144

[收稿日期:2025-02-28]